ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT

KHOA HỆ THỐNG THÔNG TIN

BÁO CÁO CUỐI KỲ

MÔN PHƯƠNG PHÁP NGHIÊN CỨU LIÊN NGÀNH

ĐỀ TÀI: ỨNG DỤNG HỌC MÁY TRONG ĐỊNH GIÁ ĐỘNG THƯƠNG MẠI ĐIỆN TỬ

Giảng viên hướng dẫn: PGS.TS. Hồ Trung Thành

Nhóm Sinh viên thực hiện: Nhóm 8

K244060767 - Phan Ngọc Bảo Châu

K244060783 - Nguyễn Mậu Khánh Linh

K244060797 - Trần Ái Quyên

K244060798 - Nguyễn Như Quỳnh

K244060805 - Nguyễn An Thái

TP.HCM, THÁNG 11/2025

THÀNH VIÊN NHÓM 8

STT	Họ và tên	Mã số sinh viên	Tỷ lệ đóng góp	Chữ ký
1	Phan Ngọc Bảo Châu	K244060767	100%	
2	Nguyễn Mậu Khánh Linh	K244060783	100%	
3	Trần Ái Quyên	K244060797	100%	
4	Nguyễn Như Quỳnh	K244060798	100%	
5	Nguyễn An Thái	K244060805	100%	

LỜI CẢM ƠN

Lời đầu tiên, nhóm nghiên cứu xin gửi lời cảm ơn chân thành đến trường Đại học Kinh tế - Luật vì đã tạo điều kiện cho nhóm có cơ hội để được học tập và nghiên cứu môn Phương pháp nghiên cứu liên ngành.

Bên cạnh đó, nhóm chúng tôi xin chân thành cảm ơn Thầy Hồ Trung Thành – Giảng viên khoa Hệ thống Thông tin – Trường Đại học Kinh tế - Luật đã tận tình giúp đỡ chúng tôi tiếp cận những kiến thức về Phương pháp nghiên cứu liên ngành, dành cho nhóm những lời khuyên và góp ý trong suốt quá trình thực hiện để nhóm nghiên cứu có thể hoàn thành một cách tốt nhất.

Mặc dù đã cố gắng để hoàn thiện song trong quá trình thực hiện chắc chắn không thể tránh khỏi những thiếu sót. Do đó, nhóm rất mong nhận được những ý kiến quan tâm, đóng góp từ thầy và các bạn để đề tài được hoàn thiện hơn.

Lời sau cùng, tập thể nhóm kính chúc thầy sức khỏe và thành công.

Tập thể nhóm 8 xin chân thành cảm ơn!

LỜI CAM KẾT

Nhóm nghiên cứu xin cam kết rằng bài nghiên cứu với đề tài "Ứng dụng học máy trong định giá động thương mại điện tử", thuộc môn Phương pháp nghiên cứu liên ngành, là sản phẩm của chính nhóm nghiên cứu. Mọi dữ liệu, ý tưởng hay tài liệu tham khảo khác được sử dụng trong nghiên cứu này đều đã được trích dẫn và ghi nhận đầy đủ, đúng quy định.

Nhóm cũng xin cam đoan rằng bài nghiên cứu này tuân thủ nghiêm túc các nguyên tắc về đạo đức học thuật. Mặc dù một số nội dung có thể được kế thừa hoặc phát triển từ những công trình trước đó trong quá trình học tập và làm việc của nhóm, nhưng đây là một công trình nghiên cứu độc lập, được nhóm biên soạn, phân tích, chỉnh sửa và hoàn thiện kỹ lưỡng, nhằm phục vụ riêng cho nghiên cứu này. Nhóm nghiên cứu hoàn toàn chịu trách nhiệm về tính trung thực, nguyên bản của nội dung và kết quả nghiên cứu đã trình bày.

Thành phố Hồ Chí Minh, 11/2025

Nhóm 8

MỤC LỤC

THÀNH VIÊN NHÓM 8 ..... *i*

LỜI CẢM ƠN ..... *ii*

LỜI CAM KẾT ..... *iii*

MỤC LỤC ..... *iv*

DANH MỤC BẢNG BIỂU ..... *vii*

DANH MỤC HÌNH ẢNH ..... *viii*

DANH MỤC TỪ VIẾT TẮT ..... *ix*

TÓM TẮT ..... *x*

TỔNG QUAN ..... *xii*

CHƯƠNG 1: TỔNG QUAN LÝ THUYẾT VÀ CÁC CÔNG VIỆC LIÊN QUAN *1*

Tổng quan chương **1**

1.1. Tổng quan tài liệu (Literature Review) và tổng quan lý thuyết (Theoretical background) **1**

1.1.1. Định giá động (Dynamic pricing) 1

1.1.2. Học tăng cường (Reinforcement Learning) 3

1.1.3. Light Gradient Boosting 4

1.2. Khoảng trống và động lực nghiên cứu **5**

1.2.1. Khoảng trống nghiên cứu 5

1.2.2. Động lực nghiên cứu 6

CHƯƠNG 2: CHUẨN BỊ DỮ LIỆU *8*

Tổng quan chương **8**

2.1. Thu thập và Mô tả Dữ liệu (Data Collection and Description) **8**

2.2. Tìm hiểu Dữ liệu (Data Understanding) **9**

2.2.1. Phân tích mô tả (Descriptive Analysis) 9
2.2.2. Danh sách các biến cho mô hình mô phỏng thị trường (LightGBM) 13
2.3. Tiền xử lý dữ liệu (Data Pre-processing) **13**
2.3.1. Xử lý Dữ liệu Thiếu (Handling Missing Data) 13
2.3.2. Phát hiện bất thường (Anomaly Detection) 14
2.3.3. Biến đổi dữ liệu (Data Transformation) 14
2.3.4. Chuẩn hóa dữ liệu (Data Standardization) 20
2.4. Phân tích dữ liệu khám phá EDA **20**
2.4.1. Phân tích thông tin các biến quan trọng 20
2.4.2. Phân tích tương quan và đa biến 22
2.4.3. Lựa chọn đặc trưng (Feature Selection) 24
2.5.1. Lựa chọn phương pháp 24
2.5.2. Thực hiện phân chia 25
CHƯƠNG 3: THỰC NGHIỆM VÀ KẾT QUẢ ***26***
Tổng quan chương **26**
3.3. Mô tả chi tiết các module **27**
3.3.1. Xử lý dữ liệu 27
3.3.2. Mô phỏng Cầu bằng LightGBM-Quantile 28
3.3.3. . Môi trường mô phỏng bất định 29
3.3.4. Tác tử học tăng cường (RL) liên tục 31
3.3.5. Mô hình giám sát phụ trợ (dự báo phản hồi khách hàng) 32
3.3.6. Phân cụm khách hàng 34
3.4. Giao thức đánh giá và chia dữ liệu **35**
3.5. Cấu hình tham số huấn luyện **37**
3.6. Chỉ số đánh giá **39**
3.7. Kết quả thực nghiệm **41**

3.7.1. Kết Quả Mô Phỏng Cầu (LightGBM-Quantile) 41
3.7.2. Phân Tích Hiệu Suất Định Lượng 41
3.7.3. Đánh giá độ tin cậy của khoảng dự báo 42
3.7.4. Ứng dụng thực tiễn: Phân tích độ co giãn cầu theo giá 43
3.7.5. Kết quả mô hình giám sát phụ trợ (phân tích phản hồi khách hàng) 43
3.7.6. Kết quả huấn luyện tác tử RL và hiệu quả định giá động 46
3.7.7. Kết quả phân cụm khách hàng và ứng dụng 47
CHƯƠNG 4: TRỰC QUAN HOÁ VÀ ĐỀ XUẤT ***50***
TÀI LIỆU THAM KHẢO ***53***

DANH MỤC BẢNG BIỂU

Bảng 2.1. Mô tả các thuộc tính trong bộ dữ liệu 8
Bảng 2.2. Thống kê mô tả các biến số 9
Bảng 2.3. Ý nghĩa và mục tiêu của mục tiêu đã chọn 14
Bảng 2.4. Chia khoảng dữ liệu Order Time 15
Bảng 2.5. Kết quả cho được 11 khoảng giá trị 16
Bảng 2.6. Phân loại theo Tứ Phân Vị 17
Bảng 2.7. Phân loại theo Khoảng Đều 17
Bảng 2.8. Mã hóa dữ liệu Subcategory 19
Bảng 3.1. Cấu hình tham số huấn luyện và triển khai cho các Module trong hệ thống định giá động 37
Bảng 3.2. So sánh độ chính xác dự báo cầu giữa mô hình LightGBM trung vị và các phương pháp tham chiếu trên tập kiểm thử 2.000 mẫu 41
Bảng 3.3. So sánh các chính sách tác động 44
Bảng 3.4. Thống kê trung bình các đặc trưng hành vi của khách hàng theo phân cụm (giá trị tính bằng đơn vị tiền tệ giả định và thang điểm đánh giá 1-5) 47

DANH MỤC HÌNH ẢNH

Hình 2.1. Biểu đồ cột Pareto phân tích các danh mục sản phẩm bán chạy..... 12

Hình 2.2. Biểu đồ Pareto: Phân tích Tần suất Tích lũy Số lượng Bán ra theo Phân khúc (City - Category)..... 12

Hình 2.3. Biểu đồ hộp của biến Price và Quantity..... 14

Hình 2 4. Số lượng đơn hàng trung bình theo giờ trong ngày..... 21

Hình 2.5. Số lượng đơn hàng trung bình theo giờ trong ngày..... 22

Hình 2.6. Biểu đồ phân phối của biến Quantity..... 22

Hình 2.7. Tương quan giữa Đơn giá và Số lượng bán..... 23

Hình 2.8. Heatmap tương quan giữa các biến số..... 24

Hình 3.1. Pipeline tổng quan của quá trình thực nghiệm định giá động – bao gồm xử lý dữ liệu, mô phỏng cầu, môi trường RL, tác tử định giá, mô hình phụ trợ và phân cụm khách hàng..... 27

Hình 4.1.Dashboard tổng quan về đơn hàng và doanh thu của Tasty Sushi Restaurant 50

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt	Định nghĩa
1	WTP	Willingness to Pay
2	RL	Reinforcement Learning
3	MDP	Markov Decision Process
4	LightGBM	Light Gradient Boosting Machine
5	GBDT	Gradient Boosting Decision Tree
6	GOSS	Gradient-based One-Side Sampling
7	EFB	Exclusive Feature Bundling
8	DRL	Deep Reinforcement Learning
9	EDA	Exploratory Data Analysis
10	DDPG	Deep Deterministic Policy Gradient
11	XGBoost	Extreme Gradient Boosting
12	RF	Random Forest
13	AUC	Area Under ROC Curve
14	MAE	Mean Absolute Error
15	RMSE	Root Mean Squared Error
16	R^2	R-squared
17	ML	Machine Learning
18	GBM	Gradient Boosting

TÓM TẮT

Nghiên cứu của nhóm tập trung vào việc ứng dụng ML để tối ưu hóa chiến lược Định giá động (Dynamic Pricing) trong lĩnh vực thương mại điện tử, cụ thể là đối với một nhà hàng giao đồ ăn trực tuyến (Tasty Sushi Restaurant). Mục tiêu kép của nghiên cứu là tối đa hóa doanh thu và đồng thời duy trì sự hài lòng của khách hàng. Cơ sở dữ liệu sử dụng là bộ dữ liệu thứ cấp gồm 10.000 bản ghi lịch sử giao dịch từ Tasty Sushi Restaurant giai đoạn 2020 – 2024, bao gồm các thông tin chi tiết về giá (Price), số lượng bán (Quantity), loại món (Category/Subcategory), thời gian (Order Date/Time), giới tính (Gender), thành phố (City), và điều kiện thời tiết (Weather).

Về mặt lý thuyết, nghiên cứu được xây dựng trên các trụ cột chính, bao gồm Định giá động, là chiến lược điều chỉnh giá linh hoạt theo thời gian thực dựa trên các yếu tố như cung - cầu thị trường và hành vi khách hàng. Khái niệm then chốt là Mức sẵn sàng chi trả (WTP) của khách hàng, mà nếu doanh nghiệp ước tính chính xác, có thể dùng để cá nhân hóa giá bán. Chiến lược này đặc biệt phổ biến trong lĩnh vực giao đồ ăn trực tuyến để thích ứng với biến động nhu cầu theo giờ cao điểm hoặc điều kiện thời tiết. Hệ thống định giá được xây dựng dựa trên hai thuật toán ML cốt lõi: LightGBM và RL. LightGBM, thuộc nhóm GBDT, được chọn để xây dựng Mô hình mô phỏng cầu (Demand Simulation) nhờ khả năng dự báo chính xác và tốc độ huấn luyện nhanh trên dữ liệu lớn, nhiều chiều. Trong khi đó, RL (với thuật toán DDPG) được sử dụng để tìm ra chính sách giá tối ưu. Thuật toán RL này hoạt động bằng cách tối đa hóa phần thưởng (reward), được định nghĩa là Doanh thu trừ đi một khoản Phạt (Penalty) tỷ lệ với bình phương độ lệch giá so với giá lịch sử, nhằm khuyến khích tối đa hóa lợi nhuận nhưng vẫn duy trì sự ổn định giá.

Quá trình chuẩn bị dữ liệu bao gồm việc xác nhận không có giá trị thiếu hoặc ngoại lệ nghiêm trọng trong các cột chính. Kỹ thuật đặc trưng (Feature Engineering) đã tạo ra các đặc trưng thời gian mới (Năm, Quý, Tháng, Ngày trong tuần, Giờ) từ Order Date và Order Time để nắm bắt quy luật chu kỳ và thời vụ. Biến Order Time được chia thành hai khoảng chính là Lunch (11:00 - 15:59) và Dinner (16:00 - 19:00). Các biến phân loại như City, Category, Weather, và Payment Method đã được mã hóa bằng phương pháp One-Hot Encoding. Cuối cùng, bộ dữ liệu 10.000 mẫu được chia bằng phương pháp Hold-out, với 80% cho tập huấn luyện (8.000 mẫu) và 20% cho tập kiểm thử (2.000 mẫu).

Mô hình mô phỏng cầu sử dụng LightGBM với Hồi quy phân vị (Quantile Regression) (alpha = 0.1, 0.5, 0.9) để dự báo phân bố lượng cầu, tạo ra yếu tố bất định của thị trường trong môi trường RL. Mô hình LightGBM trung vị (quantile 0.5) đã chứng minh

hiệu suất dự báo ấn tượng trên tập kiểm thử 2.000 mẫu, đạt MAE xấp xỉ 0.14 và hệ số xác định R^2 là 0.82. Điều này có nghĩa là mô hình giải thích được 82% biến động của cầu và có sai số dự báo rất thấp. Phân tích tầm quan trọng của đặc trưng cho thấy Price (giá bán), Category/Subcategory (loại món), và các đặc trưng thời gian (Hour, DayOfWeek) là những yếu tố quan trọng nhất ảnh hưởng đến nhu cầu.

Tác tử RL sử dụng DDPG được huấn luyện để tương tác với môi trường mô phỏng này. Chính sách RL học được đã giúp tăng tổng doanh thu trung bình 6.0% trên tập kiểm thử (từ $30.940 lên $32.800) so với chính sách giá lịch sử. Nhờ cơ chế phạt tích hợp trong hàm thưởng, chính sách RL này có tính ổn định cao, chỉ điều chỉnh giá trung bình khoảng ±7.2% mỗi phiên, tránh thay đổi giá đột ngột (> 20%).

Để quản lý mục tiêu hài lòng khách hàng, một mô hình giám sát phụ trợ sử dụng XGBoost đã được phát triển để dự báo xác suất khách hàng phản hồi "Poor" (tiêu cực). Mô hình này đạt chỉ số AUC xấp xỉ 0.91. Phân tích cho thấy giá cả là yếu tố quan trọng nhất ảnh hưởng đến phản hồi tiêu cực. Khi áp dụng chính sách RL (có phạt), tỷ lệ phản hồi "Poor" dự báo chỉ tăng nhẹ lên khoảng 12.0% so với mức 10.5% của giá lịch sử. Ngược lại, chính sách tham lam (tối đa hóa lợi nhuận mà không có phạt) làm tăng tỷ lệ này lên 17.8%, cho thấy cơ chế phạt đã thành công trong việc cân bằng giữa lợi nhuận và sự hài lòng khách hàng.

Cuối cùng, phân tích phân cụm khách hàng (K-Means) đã xác định ba nhóm chính: Cụm 1 (58%, chi tiêu thấp, nhạy cảm giá cao), Cụm 2 (32%, tầm trung), và Cụm 3 (10%, chi tiêu lớn, ít nhạy cảm giá). Chính sách RL đã áp dụng định giá vi mô phù hợp với các cụm này: tăng giá ở 75% phiên đối với Cụm 3 để tối đa hóa doanh thu từ nhóm WTP cao, và giảm/giữ giá ở 90% phiên đối với Cụm 1 để kích cầu. Sự kết hợp giữa tối ưu hóa doanh thu bằng RL và quản lý hài lòng bằng mô hình giám sát đã chứng minh tính khả thi của một chiến lược định giá đa mục tiêu.

TỔNG QUAN

Nghiên cứu này được thực hiện nhằm giải quyết bài toán tối ưu hóa chiến lược giá trong môi trường thương mại điện tử, đặc biệt là trong lĩnh vực giao đồ ăn trực tuyến tại Việt Nam, nơi sự cạnh tranh về giá là vô cùng khốc liệt. Các nhà hàng và thương hiệu kinh doanh dịch vụ ăn uống phải đối mặt với nhu cầu biến động mạnh theo thời gian và yếu tố ngữ cảnh, đòi hỏi một giải pháp định giá linh hoạt thay vì mức giá cố định truyền thống. Nghiên cứu đề xuất một khuôn khổ mô hình định giá động tích hợp các kỹ thuật học máy tiên tiến, bao gồm Học tăng cường (RL) và LightGBM. Mục tiêu chung của nghiên cứu là phát triển một hệ thống định giá tự động, thông minh để tối đa hóa tổng doanh thu và đồng thời duy trì trải nghiệm cũng như sự hài lòng của khách hàng trong ngưỡng chấp nhận được.

Nghiên cứu tập trung vào bốn mục tiêu cụ thể. Thứ nhất là xây dựng và đánh giá Mô hình mô phỏng cầu (Demand Simulation) sử dụng thuật toán LightGBM với Hồi quy phân vị (Quantile Regression) để dự báo phân bố nhu cầu (Quantity) một cách chính xác, từ đó tạo ra một môi trường mô phỏng thị trường có tính bất định. Thứ hai, thiết kế và huấn luyện Tác tử Học tăng cường (RL Agent) sử dụng thuật toán DDPG nhằm tìm ra chính sách định giá tối ưu bằng cách tối đa hóa hàm thưởng (Reward), trong đó hàm thưởng được định nghĩa là Doanh thu trừ đi một khoản Phạt (Penalty) tỷ lệ với bình phương độ lệch giá so với giá lịch sử, nhằm hạn chế sự biến động giá quá lớn gây ảnh hưởng xấu đến khách hàng. Thứ ba, phát triển Mô hình giám sát phụ trợ (Supervisory ML) sử dụng XGBoost để dự báo khả năng khách hàng phản hồi tiêu cực ("Poor") sau khi áp dụng chính sách RL, đảm bảo sự hài lòng của khách hàng không bị ảnh hưởng nghiêm trọng. Cuối cùng, thực hiện Phân cụm khách hàng (K-Means) để xác định các phân khúc có hành vi mua sắm và độ nhạy cảm giá khác nhau, từ đó phân tích tác động vi mô của chính sách RL lên từng nhóm khách hàng.

Để định lượng hiệu quả, nghiên cứu cần trả lời các câu hỏi chính như sau: LightGBM-Quantile có thể dự báo nhu cầu (Quantity) với độ chính xác cao (chỉ số R^2 xấp xỉ 0.82) và độ tin cậy bao phủ (Tỷ lệ bao phủ thực tế là 82% nằm giữa $Q_{0.1}$ và $Q_{0.9}$) như thế nào? Chính sách định giá động tìm được bởi tác tử RL (DDPG) giúp tăng tổng doanh thu trung bình bao nhiêu phần trăm trên tập kiểm thử so với chính sách giá lịch sử, với kết quả thực nghiệm đạt mức tăng 6.0%? Việc tích hợp cơ chế phạt cho biến động giá vào hàm thưởng RL có giúp hạn chế sự gia tăng tỷ lệ phản hồi tiêu cực ("Poor") trong ngưỡng chấp nhận được (< 15%), với tỷ lệ dự báo là ~ 12.0%? Và các phân khúc khách hàng (được xác

định qua K-Means) khác nhau thế nào, liệu chính sách RL có áp dụng các chiến lược giá vi mô (ví dụ: Tăng giá ở 75% phiên đối với Cụm 3 (ít nhạy cảm) và giảm/giữ giá ở 90% phiên đối với Cụm 1 (nhạy cảm cao)) cho từng phân khúc không?

Đối tượng nghiên cứu của đề tài là Mô hình Định giá Động tích hợp Học máy (gồm thuật toán RL/DDPG cho việc ra quyết định giá và LightGBM-Quantile cho việc mô phỏng cầu). Đối tượng khảo sát là Bộ dữ liệu thứ cấp gồm 10.000 bản ghi lịch sử giao dịch của Tasty Sushi Restaurant. Về phạm vi nghiên cứu, dữ liệu được sử dụng có nguồn gốc từ năm 2020 đến 2024, và phạm vi ứng dụng thực tiễn nằm trong lĩnh vực thương mại điện tử/giao đồ ăn trực tuyến.

Nghiên cứu sử dụng phương pháp Nghiên cứu ứng dụng định lượng, với quy trình thực nghiệm được xây dựng theo khuôn khổ tích hợp nhiều Module học máy. Quy trình nghiên cứu bao gồm: Thu thập và Tiền xử lý Dữ liệu (10.000 mẫu) thông qua các bước như Kỹ thuật Đặc trưng (tạo biến thời gian: Hour, DayOfWeek, Month, v.v.) và Mã hóa biến phân loại bằng One-Hot Encoding. Dữ liệu sau đó được chia thành 80% cho tập huấn luyện và 20% (2.000 mẫu) cho tập kiểm thử bằng phương pháp Hold-out. Tiếp theo là Mô hình hóa và Mô phỏng Cầu bằng LightGBM-Quantile để tạo ra môi trường mô phỏng Gym tùy chỉnh. Sau đó, Tác tử RL sử dụng DDPG được huấn luyện để tương tác với môi trường mô phỏng, với mục tiêu tối ưu hóa hàm thưởng (Revenue - Penalty). Cuối cùng là giai đoạn Phân tích Hậu nghiệm sử dụng XGBoost để đánh giá tỷ lệ phản hồi "Poor" và Phân cụm K-Means (với K = 3) để phân tích hành vi khách hàng. Việc đánh giá hiệu suất được thực hiện trên tập kiểm thử 20%, sử dụng các chỉ số như MAE, R^2, tổng doanh thu, và AUC. Các thuật toán chính được triển khai bằng ngôn ngữ Python, sử dụng các thư viện như Scikit-learn và môi trường Gym tùy biến. Mặc dù thời gian huấn luyện mô hình LightGBM và XGBoost rất nhanh (dưới 5 giây), việc huấn luyện tác tử RL mất khoảng 15 – 20 phút cho 5 episode 10.000 bước, cho thấy tính khả thi về mặt tính toán của giải pháp trong thực tế.

Nghiên cứu này mang lại ý nghĩa khoa học và thực tiễn quan trọng. Về mặt khoa học, công trình này lấp đầy khoảng trống về mô hình hóa định giá động cho lĩnh vực giao đồ ăn tại Việt Nam bằng cách kết hợp xây dựng hai kỹ thuật học máy là LightGBM và RL trên bộ dữ liệu thực tế. Về mặt thực tiễn, nghiên cứu đã chứng minh rằng chính sách RL đạt mức tăng tổng doanh thu trung bình 6.0% trên tập kiểm thử, đồng thời quản lý được sự hài lòng của khách hàng khi tỷ lệ phản hồi tiêu cực dự báo chỉ tăng nhẹ lên ~ 12.0% (trong khi chính sách tham lam tăng lên 17.8%) nhờ vào cơ chế phạt trong hàm thưởng. Hệ thống

này cung cấp một giải pháp định giá linh hoạt, dựa trên dữ liệu thực, hỗ trợ các nhà hàng và nền tảng giao đồ ăn ra quyết định giá chính xác và tự động, giảm thiểu sự phụ thuộc vào kinh nghiệm chủ quan của người quản lý. Báo cáo nghiên cứu được trình bày theo cấu trúc chuẩn mực gồm bốn chương: Chương 1 là tổng quan lý thuyết và các công việc liên quan; Chương 2 là chuẩn bị dữ liệu; Chương 3 là thực nghiệm và kết quả và Chương 4 là trực quan hoá và đề xuất.

CHƯƠNG 1: TỔNG QUAN LÝ THUYẾT VÀ CÁC CÔNG VIỆC LIÊN QUAN

Tổng quan chương

Chương này chủ yếu thiết lập cơ sở lý thuyết cho nghiên cứu bằng cách giới thiệu ba khái niệm nền tảng: Định giá động (DP), Học tăng cường (RL), và LightGBM. Định giá động là một chiến lược linh hoạt nhằm tối ưu hóa doanh thu và lợi nhuận bằng cách điều chỉnh giá sản phẩm hoặc dịch vụ theo thời gian thực dựa trên sự thay đổi của cung - cầu thị trường, hành vi khách hàng và yếu tố ngữ cảnh, được hình thành từ các nguyên lý cơ bản trong kinh tế học vi mô và tập trung vào Mức sẵn sàng chi trả (WTP) của khách hàng. Nghiên cứu này kết hợp hai kỹ thuật học máy tiên tiến: LightGBM, một thuật toán GBDT nổi bật với khả năng dự báo chính xác và tốc độ huấn luyện nhanh nhờ sử dụng chiến lược *leaf-wise* cùng các kỹ thuật GOSS và EFB, được dùng để xây dựng mô hình dự báo cầu; và Học tăng cường (RL), một loại hình học máy sử dụng mô hình khen thưởng và trừng phạt để tác nhân học cách thực hiện hành động (định giá) tối ưu trong môi trường để tối đa hóa phần thưởng. Động lực thúc đẩy nghiên cứu là nhằm lấp đầy khoảng trống về việc thiếu các mô hình định giá động kết hợp LightGBM và RL được thiết kế chuyên biệt cho ngành giao đồ ăn trực tuyến tại Việt Nam, qua đó kiểm chứng khả năng ứng dụng thực tiễn của giải pháp này trên bộ dữ liệu thực tế từ Tasty Sushi Restaurant để tối ưu hóa giá bán linh hoạt trong bối cảnh thị trường cạnh tranh khốc liệt.

1.1. Tổng quan tài liệu (Literature Review) và tổng quan lý thuyết (Theoretical background)

1.1.1. Định giá động (Dynamic pricing)

Định giá động là một chiến lược định giá linh hoạt, trong đó giá sản phẩm hoặc dịch vụ được điều chỉnh theo thời gian thực dựa trên các yếu tố như sự thay đổi của cung - cầu thị trường, điều kiện thị trường, hành vi khách hàng và yếu tố ngữ cảnh. Khác với phương pháp định giá cố định truyền thống, định giá động cho phép doanh nghiệp phản ứng nhanh với sự biến động của thị trường và hành vi tiêu dùng, từ đó tối ưu hóa doanh thu và lợi nhuận trong từng thời điểm cụ thể.

Về mặt lý thuyết, cơ sở của định giá động được hình thành từ các nguyên lý cơ bản trong kinh tế học vi mô, đặc biệt là mối quan hệ giữa đường cầu – đường cung và độ co giãn giá của nhu cầu. Khi cầu tăng hoặc cung giảm, doanh nghiệp có thể điều chỉnh giá

tăng để tối đa hóa lợi nhuận; ngược lại, khi cầu giảm, việc giảm giá giúp kích thích tiêu dùng và duy trì doanh thu ổn định theo nghiên cứu được thực hiện bởi Pindyck và Rubinfeld (2018), Nguyễn và Lưu (2022).

Một khái niệm then chốt trong định giá động là mức sẵn sàng chi trả của khách hàng WTP. Nghiên cứu của Marta Nieto-García và cộng sự (2020) chỉ ra vai trò quan trọng của WTP trong việc phân khúc khách hàng dựa trên tần suất mua hàng. Kết quả cho thấy mối quan hệ hình chữ U ngược giữa tần suất mua hàng và WTP, được trung gian bởi giá tham chiếu nội tại của khách hàng. WTP đạt đỉnh khi khách hàng thực hiện 6 giao dịch mua trong khoảng thời gian 2 năm, sau đó giảm dần khi tần suất tăng cao hơn. Phát hiện này có ý nghĩa thực tiễn quan trọng: Việc theo dõi tần suất mua hàng của khách hàng và tích hợp thông tin này vào mô hình định giá động sẽ tạo ra sự phù hợp tốt hơn giữa mức giá và WTP của từng phân khúc khách hàng. Cách tiếp cận này giúp các kỹ thuật quản lý doanh thu trở nên tập trung vào khách hàng hơn và cuối cùng nâng cao lợi nhuận thông qua việc tối ưu hóa giá theo đặc điểm hành vi mua sắm cụ thể của từng nhóm khách hàng. Mỗi khách hàng có một ngưỡng chấp nhận giá khác nhau, chịu ảnh hưởng bởi thu nhập, thói quen tiêu dùng, mức độ gấp gáp và giá trị cảm nhận của sản phẩm, nếu doanh nghiệp có thể ước lượng chính xác WTP, họ có thể cá nhân hóa giá bán, từ đó tối ưu hóa doanh thu mà vẫn duy trì sự hài lòng của khách hàng.

Bên cạnh đó, lý thuyết tối ưu hóa doanh thu (Revenue Management Theory) cũng đóng vai trò nền tảng cho định giá động. Lý thuyết Quản lý Doanh thu (Revenue Management) xây dựng các mô hình công thức quy hoạch động (dynamic programming formulations) và xấp xỉ fluid (fluid approximations) cho bài toán định giá đa sản phẩm. Theo nghiên cứu của C. Maglaras và cộng sự (2009), các mô hình này cho phép doanh nghiệp với công suất cố định lựa chọn chiến lược định giá động nhằm tối đa hóa tổng doanh thu kỳ vọng trong một khoảng thời gian hữu hạn, đồng thời cung cấp những nguyên tắc định giá (pricing heuristics) và các insight quan trọng để hướng dẫn quyết định trong thực tiễn. Chức năng của các mô hình này càng được củng cố nhờ khả năng tích hợp với các phương pháp học máy hiện đại. Cụ thể, K. Ferreira và cộng sự (2017) chỉ ra rằng việc kết hợp kỹ thuật Thompson sampling với các ràng buộc về tồn kho có thể tạo ra các thuật toán định giá động sở hữu hiệu suất lý thuyết mạnh mẽ và cho kết quả thực nghiệm khả quan, mở rộng phạm vi áp dụng từ hàng không, quảng cáo internet đến bán lẻ trực tuyến.

Trong thực tiễn, định giá động có thể được triển khai dưới nhiều hình thức khác nhau. Thứ nhất là định giá theo thời gian (time-based pricing), khi giá được điều chỉnh dựa

vào khung giờ, ngày trong tuần, hoặc mùa vụ. Thứ hai là định giá theo nhu cầu (demand-based pricing), trong đó giá tăng khi nhu cầu vượt cung và giảm khi nhu cầu thấp. Thứ ba là định giá theo cạnh tranh (competition-based pricing), tức doanh nghiệp điều chỉnh giá theo biến động giá của đối thủ nhằm duy trì khả năng cạnh tranh. Cuối cùng, định giá cá nhân hóa (personalized pricing) sử dụng dữ liệu khách hàng (như tần suất mua hàng, vị trí địa lý, hành vi tiêu dùng) để đưa ra mức giá phù hợp cho từng cá nhân hoặc nhóm khách hàng cụ thể.

Trong những năm gần đây, nhờ sự phát triển của thương mại điện tử và công nghệ dữ liệu lớn (Big Data), định giá động đã được mở rộng sang các lĩnh vực dịch vụ thời gian thực như giao đồ ăn, gọi xe công nghệ, và bán lẻ trực tuyến. Đặc biệt trong lĩnh vực giao đồ ăn trực tuyến, định giá động được áp dụng rất phổ biến nhằm thích ứng với những biến động lớn về nhu cầu theo thời gian và không gian. Chẳng hạn, hệ thống có thể tự động tăng giá vào giờ cao điểm buổi trưa hoặc buổi tối, khi nhu cầu đặt món ăn tăng cao; điều chỉnh giá theo điều kiện thời tiết như mưa bão – khi chi phí giao hàng tăng; hoặc theo vị trí địa lý, như khu vực xa trung tâm, cần chi phí vận chuyển lớn hơn giúp cân bằng giữa nhu cầu và năng lực phục vụ, tối ưu doanh thu, nâng cao trải nghiệm khách hàng thông qua việc cung cấp mức giá linh hoạt và phù hợp với từng tình huống cụ thể theo các nghiên cứu của Nguyễn (2022), Trần và Vũ (2023), Vũ và Nguyễn (2024), Bộ Công Thương (2023). Đối với nhà hàng như Tasty Sushi Restaurant, áp dụng chiến lược định giá động giúp tối ưu hóa giá bán nhằm tăng tỷ lệ đặt hàng, duy trì lợi nhuận ổn định trong khi vẫn đảm bảo trải nghiệm khách hàng.

Tuy nhiên, định giá động mang lại lợi ích, tồn tại những thách thức nhất định. Về mặt tích cực, chiến lược giúp doanh nghiệp tối đa hóa doanh thu, phân bổ nhu cầu hợp lý hơn trong các khung thời gian khác nhau, và nâng cao khả năng cạnh tranh trên thị trường. Ngược lại, nếu việc điều chỉnh giá diễn ra quá thường xuyên hoặc mức chênh lệch giá quá lớn, người tiêu dùng có thể mất niềm tin và đánh giá tiêu cực về sự minh bạch của thương hiệu.

1.1.2. Học tăng cường (Reinforcement Learning)

RL được xem là một loại hình học máy tập trung vào cách một tác nhân (agent) có thể thực hiện hành động trong môi trường để tối đa hóa các phần thưởng (reward) - tạo được nhiều reward nhất. Kỹ thuật này bắt chước quy trình học thử và sai mà con người sử dụng để đạt được mục tiêu đã đặt ra. RL giúp phần mềm tăng cường các hành động hướng tới mục tiêu, đồng thời bỏ qua các hành động làm xao lãng mục tiêu.

Thuật toán RL sử dụng mô hình khen thưởng và trừng phạt trong quy trình xử lý dữ liệu. Các thuật toán này tiếp thu ý kiến phản hồi của từng hành động và tự khám phá ra con đường xử lý tốt nhất để thu về kết quả cuối cùng. Thuật toán RL còn có khả năng trì hoãn khen thưởng. Chiến lược tổng thể tốt nhất có thể đòi hỏi phải đánh đổi một vài lợi ích trước mắt, vì vậy cách tiếp cận tốt nhất mà RL khám phá ra có thể bao gồm một số trừng phạt hoặc giai đoạn quay lui. RL là phương thức hiệu quả giúp hệ thống trí tuệ nhân tạo (AI) đạt kết quả tối ưu trong môi trường chưa biết.

Có hai loại mô hình chính được phân chia dựa trên tính chất của RL: Model-based (dựa trên mô hình) và Model-free (không dựa trên mô hình). Mỗi mô hình đều có ưu nhược điểm khác nhau, dựa vào mục tiêu của các nghiên cứu mà lựa chọn mô hình phù hợp để sớm đạt được kết quả nghiên cứu. Model-based cần có MDP để thực hiện và nó có thể tự huấn luyện dựa trên MDP nhưng cần phải đào tạo lại để để tối đa hoá khả năng tính toán trong một nhiệm vụ cụ thể. Ngược lại, model-free không yêu cầu MDP, mọi tính toán đều dựa trên việc cố gắng ước tính một số giá trị trung bình theo thời gian mà không cần theo dõi những gì đã được thực hiện trước đó. Điều này giúp thực hiện tốt các tác vụ lớn, giảm giả định nhưng dễ đưa ra các quyết định không có tính ứng dụng, bị quá khớp (overfit) khi gặp bài toán phức tạp.

Trường hợp áp dụng RL vào lĩnh vực giao đồ ăn, Ashman Mehra và cộng sự (2024) đã phát triển DeliverAI - thuật toán chia sẻ đường đi dựa trên RL, giảm 12% quy mô đội xe, giảm 13% quãng đường di chuyển và tăng 50% hiệu suất sử dụng đội xe. Hay Suleiman Abahussein và cộng sự (2023) sử dụng multi-agent reinforcement learning để hướng dẫn shipper đến khu vực có nhu cầu cao, tăng số đơn hàng nhận được. Qua các nghiên cứu đã nêu, chúng tôi cũng phần nào nhận thức được ảnh hưởng không nhỏ của RL đến lĩnh vực này. Đồng thời khái quát được mối quan hệ cộng tác giữa RL và lĩnh vực giao đồ ăn.

1.1.3. Light Gradient Boosting

LightGBM là một thuật toán học máy tiên tiến thuộc nhóm GBDT, nổi bật và được ứng dụng trong nhiều lĩnh vực nhờ khả năng dự báo chính xác, tốc độ huấn luyện nhanh và giảm thiểu vấn đề overfitting hay các vấn đề liên quan. LightGBM được phát triển để khắc phục các hạn chế về hiệu suất và khả năng mở rộng của các thuật toán boosting truyền thống, đặc biệt khi áp dụng cho các bài toán có số lượng đặc trưng lớn và dữ liệu khổng lồ như trong lĩnh vực giao đồ ăn trực tuyến.

LightGBM hoạt động dựa trên nguyên lý boosting, kết hợp nhiều cây quyết định yếu thành một mô hình mạnh thông qua quá trình huấn luyện lặp lại, mỗi lần tập trung vào

các điểm dữ liệu khó dự báo. Điểm khác biệt của LightGBM so với các thuật toán boosting khác là sử dụng chiến lược phát triển cây theo hướng leaf-wise thay vì level-wise, giúp giảm thiểu hàm mất mát nhanh hơn và tăng độ chính xác dự báo. Ngoài ra, LightGBM còn tích hợp hai kỹ thuật nổi bật:

- GOSS: Tập trung vào các mẫu có gradient lớn, giúp tăng tốc độ huấn luyện mà vẫn giữ được độ chính xác.

- EFB: Gộp các đặc trưng hiếm khi đồng thời xuất hiện, giảm số chiều dữ liệu mà không làm mất thông tin quan trọng.

Trong lĩnh vực giao đồ ăn trực tuyến, định giá động đòi hỏi dự báo chính xác nhu cầu, giá tối ưu và các yếu tố thị trường biến động theo thời gian thực. LightGBM được ứng dụng rộng rãi nhờ các ưu điểm: Một là, dự báo nhu cầu và giá động: LightGBM cho phép xây dựng mô hình dự báo số lượng đơn hàng, biến động giá theo thời gian, giúp nền tảng điều chỉnh giá linh hoạt theo nhu cầu thực tế. Hai là, xử lý dữ liệu lớn, nhiều chiều: Các nền tảng giao đồ ăn thường có dữ liệu phức tạp (thời gian, vị trí, thời tiết, hành vi khách hàng), LightGBM xử lý hiệu quả các đặc trưng này, cho kết quả dự báo nhanh và chính xác. Ba là, so sánh với các thuật toán khác: Nghiên cứu thực nghiệm cho thấy LightGBM có tốc độ huấn luyện nhanh hơn XGBoost, trong khi độ chính xác dự báo tương đương hoặc nhỉnh hơn, rất phù hợp với yêu cầu cập nhật giá động liên tục.

1.2. Khoảng trống và động lực nghiên cứu

1.2.1. Khoảng trống nghiên cứu

Mặc dù định giá động đã được ứng dụng rộng rãi trong các lĩnh vực như hàng không, khách sạn và bán lẻ, song trong ngành giao đồ ăn trực tuyến tại Việt Nam, hướng nghiên cứu vẫn còn tương đối mới mẻ và thiếu tính hệ thống. Các công trình hiện có chủ yếu tập trung vào việc phân tích hành vi tiêu dùng, chiến lược khuyến mãi, hoặc tối ưu quy trình giao hàng, trong khi chưa có mô hình định giá động nào được thiết kế chuyên biệt cho lĩnh vực giao đồ ăn. Đặc thù của ngành là nhu cầu biến động mạnh theo thời gian, thời tiết và vị trí địa lý. Do đó, việc phát triển một mô hình định giá phù hợp, có khả năng phản ứng nhanh với thay đổi của thị trường, là nhu cầu thực tiễn nhưng vẫn chưa được khai thác đúng mức.

Một khoảng trống khác nằm ở việc thiếu các nghiên cứu kết hợp mô hình học máy LightGBM và RL trong bài toán định giá động. Việc kết hợp nhiều kỹ thuật vào để xây dựng mô hình giúp nâng cao hiệu quả và khắc phục một số điểu yếu của mô hình đơn lẻ trước đó.

Trong khi nhiều nghiên cứu quốc tế đã chứng minh tiềm năng của các mô hình trong dự báo giá và nhu cầu, hầu như chưa có công trình nào tại Việt Nam kiểm định và đánh giá mức độ chính xác, độ ổn định, cũng như khả năng ứng dụng thực tiễn của chúng trong môi trường dữ liệu thực tế từ các nhà hàng hoặc nền tảng giao đồ ăn.

Ngoài ra, việc khai thác dữ liệu hành vi khách hàng và yếu tố ngữ cảnh vẫn còn rất hạn chế trong các nghiên cứu trong nước. Các yếu tố như thời tiết, giờ cao điểm, khu vực giao hàng, chương trình khuyến mãi hoặc tần suất đặt món có ảnh hưởng rõ rệt đến quyết định mua hàng và khả năng chấp nhận giá của người tiêu dùng, nhưng lại chưa được tích hợp đầy đủ trong các mô hình dự báo giá. Việc bỏ qua những biến ngữ cảnh khiến các mô hình định giá thiếu khả năng thích ứng với điều kiện thực tế, làm giảm hiệu quả trong việc tối ưu doanh thu.

Nghiên cứu được thực hiện nhằm lấp đầy khoảng trống về mô hình hóa định giá động cho lĩnh vực giao đồ ăn tại Việt Nam, thông qua việc kết hợp xây dựng hai kỹ thuật học máy – LightGBM và RL – trên bộ dữ liệu thực tế của Tasty Sushi Restaurant. Nghiên cứu đóng góp về mặt học thuật trong lĩnh vực ứng dụng trí tuệ nhân tạo vào kinh tế số, có ý nghĩa thực tiễn, hỗ trợ các nhà hàng và nền tảng giao đồ ăn ra quyết định giá linh hoạt, chính xác và dựa trên dữ liệu thực.

1.2.2. Động lực nghiên cứu

Thị trường giao đồ ăn trực tuyến tại Việt Nam đang phát triển mạnh mẽ, với sự tham gia của hàng loạt nền tảng lớn như GrabFood, Shopee Food… mức độ cạnh tranh giữa các doanh nghiệp ngày càng khốc liệt. Các nhà hàng và thương hiệu kinh doanh dịch vụ ăn uống phải cạnh tranh về chất lượng món ăn, thời gian giao hàng, về chiến lược giá – yếu tố then chốt ảnh hưởng trực tiếp đến quyết định mua hàng của người tiêu dùng. Sự thay đổi nhanh chóng về nhu cầu, thói quen tiêu dùng và điều kiện thị trường đòi hỏi các doanh nghiệp phải tối ưu hóa giá bán một cách linh hoạt và hiệu quả, thay vì áp dụng mức giá cố định truyền thống.

Việc ứng dụng học máy vào định giá động nhằm nâng cao độ chính xác trong dự báo nhu cầu và hành vi khách hàng, giúp tự động hóa quá trình ra quyết định giá, giảm thiểu sự phụ thuộc vào kinh nghiệm chủ quan của người quản lý, đặc biệt quan trọng trong môi trường thương mại điện tử, nơi dữ liệu phát sinh liên tục và biến động mạnh.

Một động lực quan trọng khác của nghiên cứu là khai thác dữ liệu thực tế từ Tasty Sushi Restaurant – một doanh nghiệp đang hoạt động trong lĩnh vực giao đồ ăn trực tuyến. Bộ dữ liệu phản ánh đặc trưng những yếu tố ảnh hưởng đến định giá động, bao gồm biến

động giá, tần suất đặt hàng, phản hồi khách hàng và yếu tố ngữ cảnh (như thời tiết, thời gian, địa điểm). Đây là nguồn dữ liệu quý giá để kiểm chứng khả năng ứng dụng thực tiễn của các mô hình học máy kết hợp giữa RL và LightGBM trong bài toán định giá động.

CHƯƠNG 2: CHUẨN BỊ DỮ LIỆU

Tổng quan chương

Chương này trình bày chi tiết và có hệ thống toàn bộ quy trình chuẩn bị dữ liệu, một giai đoạn nền tảng và mang tính quyết định đến sự thành công của toàn bộ mô hình. Mục tiêu cốt lõi của chương là biến đổi dữ liệu giao dịch thô từ Tasty Sushi restaurant.csv thành một bộ dữ liệu có cấu trúc, chất lượng cao và sẵn sàng cho việc huấn luyện các mô hình Hồi quy Phân vị LightGBM (LightGBM Quantile Regression). Các mô hình này sẽ hợp thành một môi trường mô phỏng (Simulator) đủ thực tế để huấn luyện tác nhân DRL ở giai đoạn sau. Quy trình tổng thể, từ thu thập đến phân chia dữ liệu.

2.1. Thu thập và Mô tả Dữ liệu (Data Collection and Description)

Nghiên cứu sử dụng bộ dữ liệu thứ cấp có tên Tasty Sushi restaurant.csv, chứa 10.000 bản ghi về lịch sử giao dịch của một nhà hàng có thực là Tasty Sushi trong giai đoạn từ 2020 đến 2024. Bộ dữ liệu này bao gồm các thông tin chi tiết về đơn hàng, khách hàng và các yếu tố ngữ cảnh tại thời điểm đặt hàng. Cấu trúc của bộ dữ liệu được mô tả trong Bảng 2.1.

Bảng 2.1. Mô tả các thuộc tính trong bộ dữ liệu

Tên thuộc tính	Kiểu dữ liệu	Diễn giải	Ví dụ
Order ID	Số nguyên	Mã định danh duy nhất cho mỗi đơn hàng.	1, 2, 3
First Name	Chuỗi	Tên của khách hàng.	Isabella, Ethan
Last Name	Chuỗi	Họ của khách hàng.	Smith, Anderson
Gender	Chuỗi	Giới tính của khách hàng.	Female, Male
City	Chuỗi	Thành phố nơi đặt hàng.	Burnley, Salford

Order Date	Ngày	Ngày đặt hàng.	2021-12-04
Order Time	Thời gian	Thời gian đặt hàng.	15:57
Order Type	Chuỗi	Loại hình đơn hàng (Ăn tại chỗ hoặc Mang đi).	Eat-in, Takeaway
Category	Chuỗi	Danh mục chính của món ăn.	Street food, Maki
Subcategory	Chuỗi	Danh mục phụ của món ăn.	Gyoza, Hoso Maki
Price	Số thực	Đơn giá của một sản phẩm tại thời điểm đặt hàng.	2.55, 6.33
Quantity	Số nguyên	**Biến mục tiêu**: Số lượng sản phẩm được bán.	4, 3, 0
Total Price	Số thực	Tổng giá trị của mục sản phẩm (Price * Quantity).	10.2, 18.99
Weather	Chuỗi	Điều kiện thời tiết tại thời điểm đặt hàng.	Windy, Sunny
Payment Method	Chuỗi	Phương thức thanh toán.	Credit Card, Cash

2.2. Tìm hiểu Dữ liệu (Data Understanding)

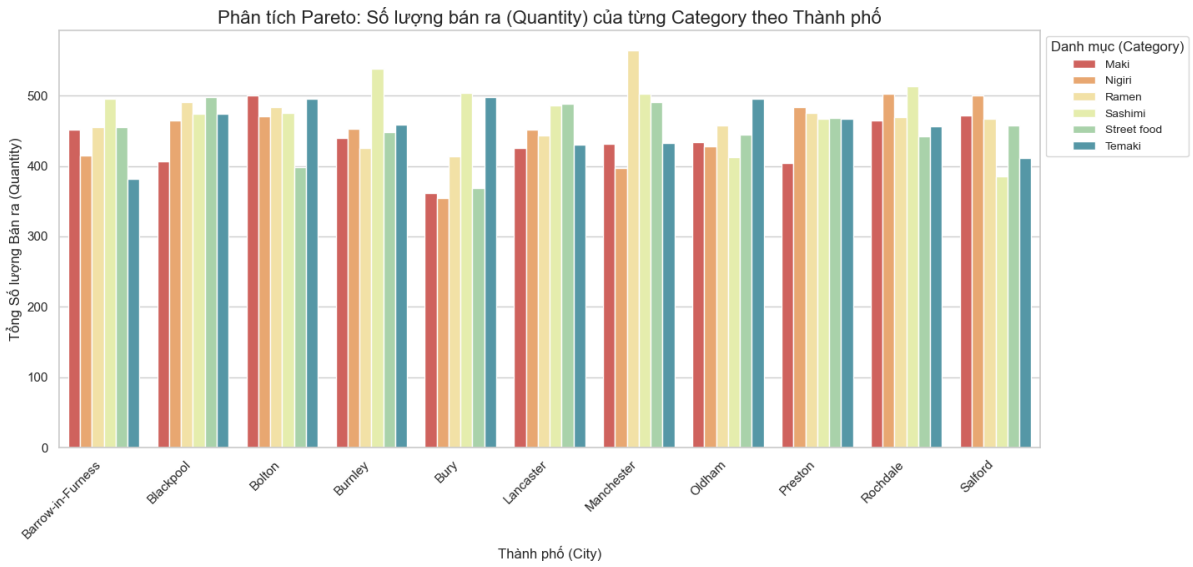
2.2.1. Phân tích mô tả (Descriptive Analysis)

Bảng 2.2. Thống kê mô tả các biến số

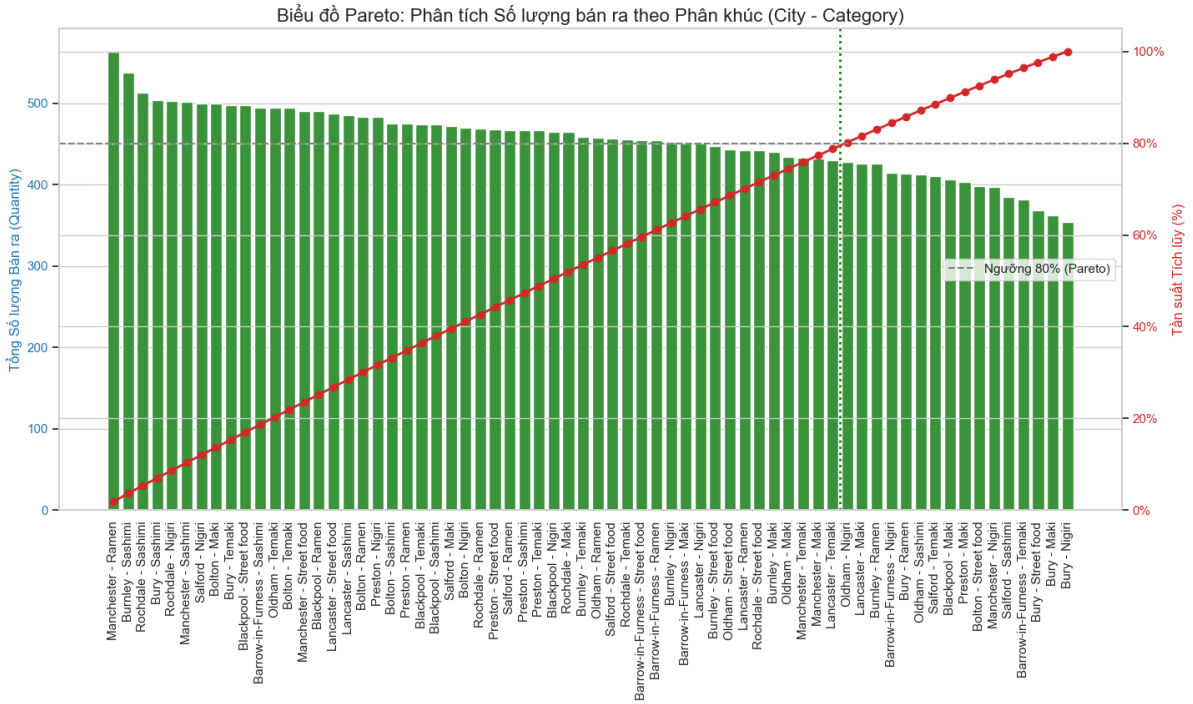
Thống kê	**Price**	**Quantity**	**Total Price**	**Ý nghĩa**

Count	10,000	10,000	10,000	**Kích thước mẫu.** Cho biết có 10,000 giao dịch hợp lệ được phân tích, đảm bảo tính đại diện cao.
Mean	5.14	3.01	15.47	**Giá trị trung bình.** Khách hàng trung bình mua món ăn giá $5.14, mua 3.01 món/đơn hàng, và chi tổng cộng $15.47 cho mỗi đơn hàng.
Std Dev	2.25	1.42	10.46	**Độ phân tán.** Độ chênh lệch giá ($2.25) và tổng giá ($10.46) so với giá trị trung bình là **rất lớn** (đặc biệt là Total Price), cho thấy thị trường có nhiều loại sản phẩm và phân khúc khách hàng đa dạng.
Min	1.50	1.00	1.51	Giá/tổng giá thấp nhất tuyệt đối.
25%	3.55	2.00	7.50	**Phân khúc Giá thấp:** 25% món ăn có giá ≤ 3.55. 25% đơn hàng có tổng giá trị ≤ 7.50. Đây là ranh giới trên của phân khúc sản phẩm/đơn hàng giá rẻ nhất.
50% (Median)	4.70	3.00	13.05	**Giá trị Trung tâm/Cốt lõi:** 50% món ăn có giá ≤ 4.70. 50% đơn hàng có tổng giá trị ≤ 13.05. Đây là **mức giá/tổng giá tiêu chuẩn** mà phần lớn khách hàng giao dịch.
75%	6.15	4.00	20.73	**Ranh giới Phân khúc Cao:** 75% món ăn có giá ≤ 6.15. 75% đơn hàng có tổng giá trị ≤ 20.73. Đây là ranh giới dưới của **Top 25%** sản

				phẩm/đơn hàng đắt tiền nhất (Phân khúc Cao cấp).
IQR (Q3 - Q1)	2.60	2.00	13.23	**Độ phân tán cốt lõi:** Phạm vi giá (Price) và Tổng giá (Total Price) của 50% dữ liệu nằm giữa Q1 và Q3. IQR càng lớn, giá càng biến động trong phân khúc trung tâm.
Max	11.99	5.00	59.95	Giá/tổng giá cao nhất tuyệt đối.
Range	10.49	4.00	58.44	Khoảng cách giữa giá trị lớn nhất và nhỏ nhất.
Skewness (Độ xiên)	1.09	-0.01	1.31	**Hình dạng Phân phối.** Price (1.09) và Total Price (1.31) có **độ lệch phải mạnh** (> 1). Điều này xác nhận rằng **phần lớn giao dịch tập trung ở giá trị thấp**, nhưng có một số ít món/đơn hàng giá trị cực kỳ cao (đuôi kéo dài về phía dương).
Kurtosis (Độ nhọn)	0.92	-1.31	2.0	**Độ tập trung đỉnh.** Total Price (2.03) có độ nhọn cao (*leptokurtic*), cho thấy dữ liệu có **nhiều ngoại lệ** và tập trung đỉnh hơn phân phối chuẩn, càng khẳng định sự tồn tại của **phân khúc đơn hàng siêu cao cấp**.



Hình 2.1. Biểu đồ cột Pareto phân tích các danh mục sản phẩm bán chạy



Hình 2.2. Biểu đồ Pareto: Phân tích Tần suất Tích lũy Số lượng Bán ra theo Phân khúc (City - Category)

Nhận xét:

- **Biến số:** Price (Đơn giá) có độ lệch chuẩn khá cao so với giá trị trung bình, cho thấy sự phân bổ rộng và khả năng đã có sự điều chỉnh giá trong lịch sử. Biến Quantity có

phân phối gần đối xứng, không bị lệch nhiều, là một tín hiệu tốt cho mô hình hồi quy. Quantity có giá trị nhỏ nhất là 0, đây là một điểm dữ liệu quan trọng, cho thấy các trường hợp khách hàng không mua hàng ở một mức giá nhất định.

- **Biến phân loại:** Phân tích Pareto (Hình 2.2) cho thấy một số ít danh mục sản phẩm (ví dụ: Maki, Street food) chiếm phần lớn doanh số, tuân theo quy luật 80/20. Điều này gợi ý rằng Category và Subcategory là những đặc trưng có sức ảnh hưởng lớn đến nhu cầu.

2.2.2. Danh sách các biến cho mô hình mô phỏng thị trường (LightGBM)

Dựa trên phân tích ban đầu và mục tiêu nghiên cứu, nhóm xác định các biến sẽ được sử dụng để xây dựng mô hình:

- **Biến mục tiêu (Target Variable):** Quantity.

- **Các biến độc lập (Features):** Price, Gender, City, Subcategory, Order Type, Category, Weather, Payment Method, và các biến thời gian được tạo ra ở bước sau.

2.3. Tiền xử lý dữ liệu (Data Pre-processing)

Đây là bước quan trọng nhất để chuyển đổi dữ liệu thô thành định dạng phù hợp cho mô hình **LightGBM**.

Các bước thực hiện:

Bước 1: Bắt đầu: Dữ liệu thô ("Tasty_sushi_restaurant.csv") được sử dụng làm dữ liệu đầu vào.

Bước 2: Xử lý Dữ liệu Thiếu & Bất thường: Các giá trị thiếu hoặc bất thường trong dữ liệu được phát hiện và xử lý.

Bước 3: Kỹ thuật Đặc trưng (Feature Engineering): Các đặc trưng mới được tạo ra từ dữ liệu hiện có để cải thiện khả năng phân tích.

- Tạo cột **'Order_Timestamp'** từ thông tin ngày và giờ.

- Trích xuất các đặc trưng thời gian: **Ngày trong tuần**, **Tháng**, **Giờ**.

Bước 4: Mã hóa Biến phân loại (Categorical Encoding): Các biến phân loại như **Gender**, **City**, **Category** được mã hóa thành dạng số, sử dụng phương pháp **One-Hot Encoding**.

Bước 5: Kết quả: Bộ dữ liệu đã qua xử lý sẵn sàng cho các bước phân tích hoặc mô hình học máy tiếp theo.

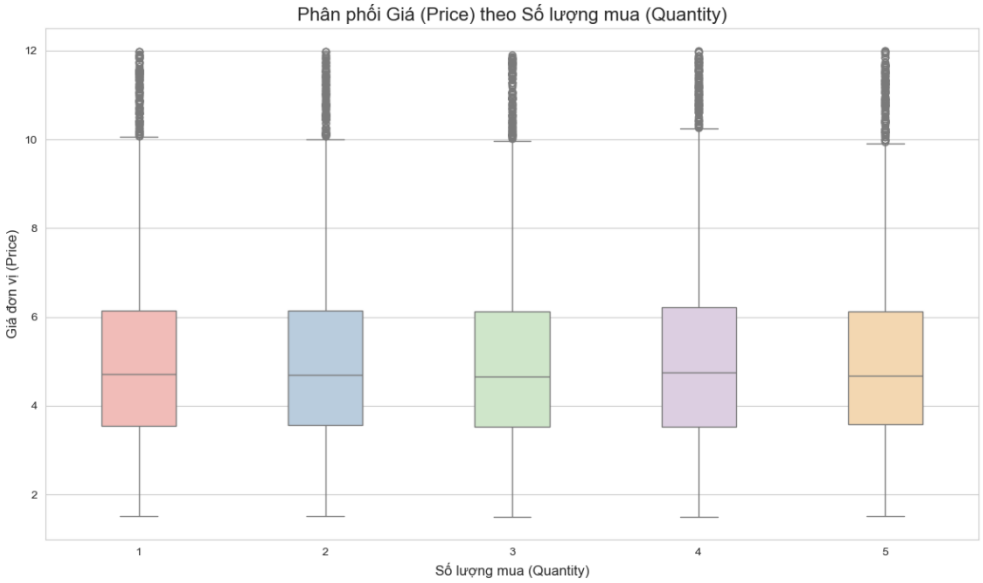
2.3.1. Xử lý Dữ liệu Thiếu (Handling Missing Data)

Bước đầu tiên trong tiền xử lý là kiểm tra sự tồn tại của các giá trị thiếu (NaN, Null). Nhóm đã thực hiện kiểm tra trên toàn bộ bộ dữ liệu và xác nhận rằng không có bất kỳ giá

trị thiếu nào. Điều này cho thấy dữ liệu có chất lượng tốt và không cần các kỹ thuật điền giá trị (imputation).

2.3.2. Phát hiện bất thường (Anomaly Detection)

Biểu đồ Boxplot cho thấy sự hiện diện đáng kể của các điểm ngoại lệ (outliers) trong biến Giá bán (Price), tập trung chủ yếu ở phía giá cao và xuất hiện đồng nhất ở mọi nhóm Số lượng (Quantity). Chúng được coi là ngoại lệ tiềm năng vì chúng có thể đại diện cho lỗi nhập liệu hoặc các giao dịch/sự kiện kinh doanh hiếm gặp có giá trị cao bất thường.



Hình 2.3. Biểu đồ hộp của biến Price và Quantity

2.3.3. Biến đổi dữ liệu (Data Transformation)

Thực hiện các thao tác chuyển đổi dữ liệu về dạng thích hợp hơn cho phân tích hoặc mô hình hóa. Quá trình này bao gồm kỹ thuật đặc trưng và mã hóa biến phân loại. Mục tiêu: Giúp mô hình dễ xử lý hơn, tăng tính diễn giải, hoặc phù hợp với các thuật toán yêu cầu biến phân loại.

a. Kỹ thuật đặc trưng (Feature Engineering): Từ các cột Order Date và Order Time, nhóm tạo ra các đặc trưng thời gian mới để mô hình có thể nắm bắt được các quy luật có tính chu kỳ và thời vụ.

Trích xuất các đặc trưng thời gian: Month (Tháng), Quarter, Year (Năm) Hour (Giờ).

Bảng 2.3. Ý nghĩa và mục tiêu của mục tiêu đã chọn

Đặc trưng mới	Ý nghĩa và mục tiêu phân tích
Order Year (Năm)	Phân tích xu hướng **dài hạn** (Long-term Trend) và tốc độ **tăng trưởng** doanh số qua các năm.
Order Quarter (Quý)	Phân tích **chu kỳ kinh doanh** lớn, thường được dùng để báo cáo và so sánh hiệu suất hàng quý.
Order Month (Tháng)	Phân tích **tính thời vụ** (Seasonality) theo tháng, ví dụ: Doanh số tăng vào các tháng hè hay tháng lễ.
Order DayOfWeek (Ngày trong tuần)	Phân tích **tính chu kỳ ngắn hạn**, so sánh hiệu suất bán hàng giữa ngày thường và cuối tuần.
Order Hour (Giờ)	Phân tích **hành vi mua hàng trong ngày**, xác định các khung giờ cao điểm (ví dụ: Giờ ăn trưa 12−14h và giờ ăn tối 18−20h) để tối ưu hóa nhân sự và chiến dịch quảng cáo.

b. Chia khoảng dữ liệu:

i. Chia khoảng dữ liệu Order Time: Xác định thời gian gọi món rơi vào bữa ăn nào trong ngày. Chuyển đổi từ dữ liệu định lượng (Time) thành dữ liệu định tính (Meal). Dựa trên khoảng thời gian nhà hàng Tasty Sushi mở cửa (11:00) và đóng cửa ngưng nhận đặt món (19:00) nhóm quyết định phân chia như sau:

Bảng 2.4. Chia khoảng dữ liệu Order Time

Time	Meal
11:00 - 15:59	Lunch
16:00 - 19:00	Dinner

ii. Chia khoảng dữ liệu Price:

- Phân tích sơ bộ về Price

+ Min: 1.5

+ Max: 11.99

+ Mean: ≈ 5.14

→ Dữ liệu trải dài. Nhóm quyết định chia theo khoảng đều, với khoảng cách là 1$. Kết quả cho được 11 khoảng giá trị như sau:

Bảng 2.5. Kết quả cho được 11 khoảng giá trị

Nhóm	Khoảng giá trị
1	[1.5 - 2.5)
2	[2.5 - 3.5)
3	[3.5 - 4.5)
4	[4.5 - 5.5)
5	[5.5 - 6.5)
6	[6.5 - 7.5)
7	[7.5 - 8.5)
8	[8.5 - 9.5)
9	[9.5 - 10.5)
10	[10.5 - 11.5)
11	[11.5 - 12.5)

- Phân loại theo Giá trị Tuyệt đối (Absolute Price): Phương pháp này dựa trên kinh nghiệm kinh doanh hoặc mục tiêu phân khúc đã định sẵn:

+ Phân khúc "Thử nghiệm": Phạm vi giá dưới $5.00 có ý nghĩa kinh doanh là khách hàng mua thử, đơn hàng rất nhỏ.

+ Phân khúc "Phổ thông": Phạm vi giá từ $5.00 đến $15.00 có ý nghĩa kinh doanh là phần lớn giao dịch cốt lõi, thường nằm quanh mức trung vị ($13.05).

+ Phân khúc "Cao cấp": Phạm vi giá từ $15.00 đến $30.00 có ý nghĩa kinh doanh là đơn hàng có giá trị cao.

+ Phân khúc "VIP": Phạm vi giá trên $30.00 có ý nghĩa kinh doanh là khách hàng chi tiêu lớn nhất.

- Phân loại theo Tứ Phân Vị (Quartiles): Phương pháp này sử dụng các chỉ số Q1, Median (Q2), Q3 đã tính toán để phân chia dữ liệu thành bốn nhóm có kích thước bằng nhau (mỗi nhóm chiếm 25% tổng số đơn hàng).

Bảng 2.6. Phân loại theo Tứ Phân Vị

Phân khúc	Phạm vi giá (Total Price)	Tỷ lệ đơn hàng	Giá trị
Phân khúc 1 (Thấp nhất)	Dưới Q1	25%	Dưới $7.50
Phân khúc 2 (Trung bình Thấp)	Q1 đến Median	25%	$7.50 đến $13.05
Phân khúc 3 (Trung bình Cao)	Median đến Q3	25%	$13.05 đến $20.73
Phân khúc 4 (Cao nhất)	Trên Q3	25%	Trên $20.73

Ưu điểm: Phương pháp này đảm bảo số lượng đơn hàng trong mỗi nhóm là tương đương nhau (25%), giúp việc so sánh hiệu quả hơn.

- Phân loại theo Khoảng Đều (Equal Width): Phương pháp này chia toàn bộ phạm vi tổng giá Total Price (Max - Min) thành các khoảng có độ rộng bằng nhau.

+ Min = $1.51

+ Max = $59.95

+ Phạm vi = $58.44

+ Chia thành 5 khoảng đều (ví dụ), độ rộng mỗi khoảng sẽ là: Độ $rộng = \frac{Min-Max}{Số\ lượng\ nhóm} = \frac{59.95-1.51}{5} \approx \$11.69$

Bảng 2.7. Phân loại theo Khoảng Đều

Phân khúc	Phạm vi giá (Total Price)
Nhóm 1	$1.51 đến $13.20
Nhóm 2	$13.20 đến $24.89
Nhóm 3	$24.89 đến $36.58
Nhóm 4	$36.58 đến $48.27
Nhóm 5	$48.27 đến $59.95

Nhược điểm: Mặc dù độ rộng khoảng đều nhau, nhưng do dữ liệu Total Price bị lệch mạnh về phía thấp (Skewness > 1), nên các nhóm có tổng giá trị cao (Nhóm 3, 4, 5) sẽ chứa rất ít đơn hàng.

c. Mã hóa biến phân loại (Categorical Encoding): Nhóm sử dụng phương pháp **One-Hot Encoding** để chuyển đổi các biến phân loại sang dạng số mà mô hình có thể hiểu được. Phương pháp này được chọn vì các biến như City hay Category là các biến định danh không có thứ tự.

Các biến được mã hóa: Gender, City, Meal, Order Type, Category, Subcategory, Customer Review, Weather, Payment Method.

- Gender: (2 loại)
+ Female:0
+ Male:1
- City: (11 loại)
+ Barrow-in-Furness: 0
+ Blackpool: 1
+ Bolton: 2
+ Burnley: 3
+ Bury: 4
+ Lancaster: 5
+ Manchester: 6
+ Oldham: 7
+ Preston: 8
+ Rochdale: 9
+ Salford: 10
- Meal: (2 loại)
+ Lunch: 0
+ Dinner: 1
- Order Type: (2 loại)
+ Eat-in: 0
+ Takeaway:1
- Category: (5 loại)
+ Maki: 0
+ Nigiri: 1
+ Ramen: 2
+ Sashimi: 3
+ Street food: 4

+ Temaki: 5

- Subcategory: (62 loại)

Bảng 2.8. Mã hóa dữ liệu Subcategory

Beef Ramen: 0	Miso Ramen: 21	Spicy Miso Ramen: 41
California Roll: 1	Miso Soup: 22	Spicy Salmon: 42
Chawanmushi: 2	Octopus: 23	Spicy Tuna: 43
Chicken Ramen: 3	Okonomiyaki: 24	Spicy Tuna Roll: 44
Cold Ramen: 4	Onigiri: 25	Squid Sashimi: 45
Crab: 5	Philadelphia Roll: 26	Sweet Egg: 46
Crab Sashimi: 6	Rainbow Roll: 27	Sweet Egg Sashimi: 47
Crab Stick: 7	Salmon: 28	Takoyaki: 48
Cucumber Roll: 8	Salmon Avocado: 29	Tempura Roll: 49
Curry Ramen: 9	Salmon Sashimi: 30	Tonkotsu Ramen: 50
Dragon Roll: 10	Scallop: 31	Tuna: 51
Edamame: 11	Scallop Sashimi: 32	Tuna Avocado: 52
Eel: 12	Sea Urchin: 33	Tuna Sashimi: 53
Eel Cucumber: 13	Sea Urchin Sashimi: 34	Uramaki: 54
Futomaki: 14	Seafood Ramen: 35	Vegetable: 55
Gyoza: 15	Shio Ramen: 36	Vegetable Ramen: 56
Hoso Maki: 16	Shoyu Ramen: 37	Vegetarian Ramen: 57
Karaage: 17	Shrimp: 38	Yakitori: 58
Korokke: 18	Shrimp Tempura: 39	Yellowtail: 59
Mackerel: 19	Smelt Roe: 40	Yellowtail Sashimi: 60
Mackerel Sashimi: 20		Yellowtail Scallion: 61

- Customer Review: (3 loại)

+ Poor: 0

+ Good:1

+ Excellent: 2

- Weather: (3 loại)

+ Sunny: 0

+ Windy: 1

+ Rainy: 2

- Payment Method: (4 loại)

+ Cash: 0

+ Credit Card: 1

+ Debit Card: 2

+ Mobile Payment: 3

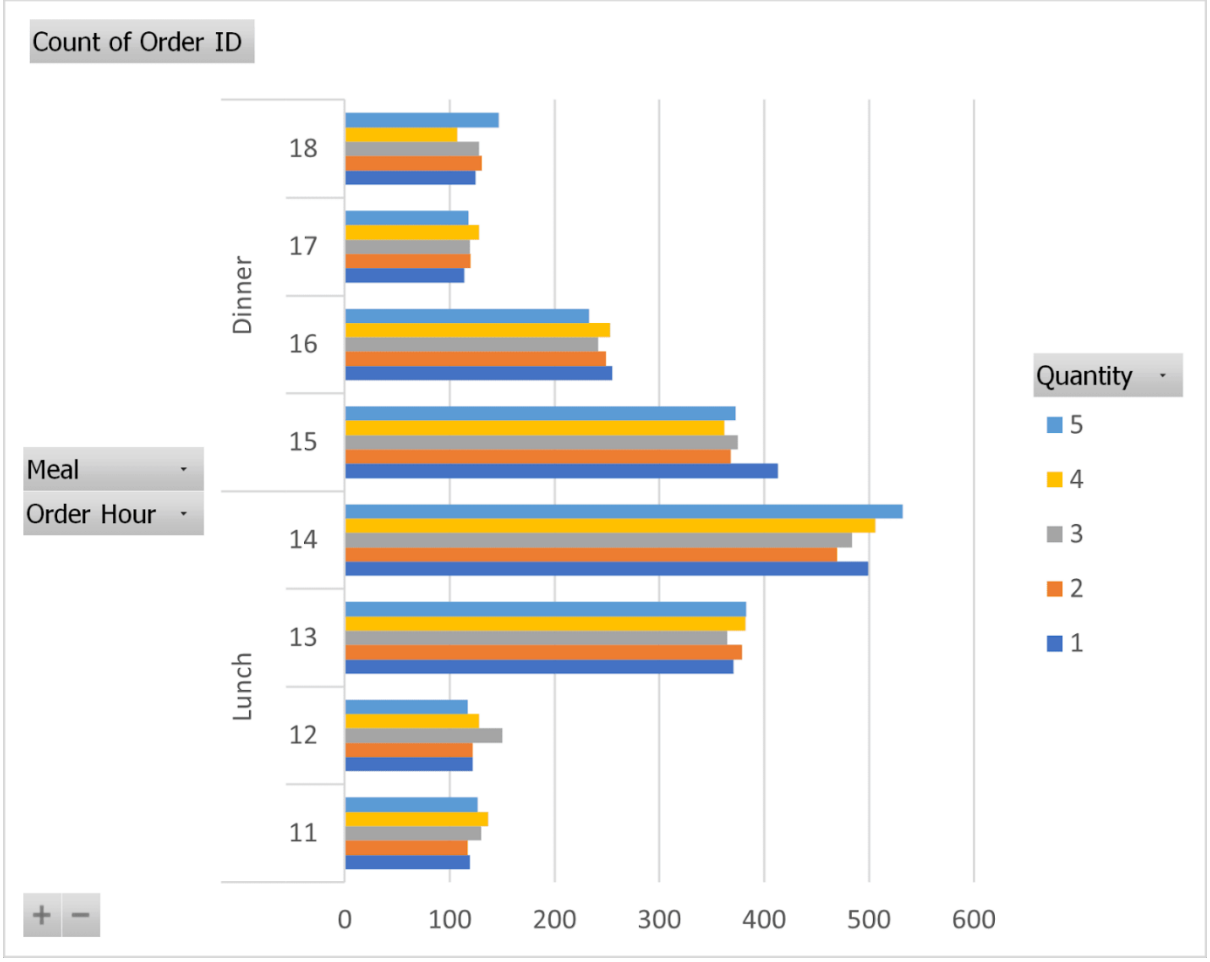
2.3.4. Chuẩn hóa dữ liệu (Data Standardization)

Chuẩn hóa dữ liệu là bước đưa các biến số về cùng một thang đo. Tuy nhiên, các mô hình dựa trên cây quyết định như **LightGBM** có tính chất bất biến với các phép biến đổi đơn điệu trên từng đặc trưng (scale-invariant). Lý do là vì thuật toán chỉ quan tâm đến điểm phân chia (threshold) tối ưu trên từng biến để giảm thiểu hàm mất mát, chứ không dựa vào khoảng cách Euclid giữa các điểm dữ liệu. Do đó, bước chuẩn hóa dữ liệu không bắt buộc và được bỏ qua trong nghiên cứu này.

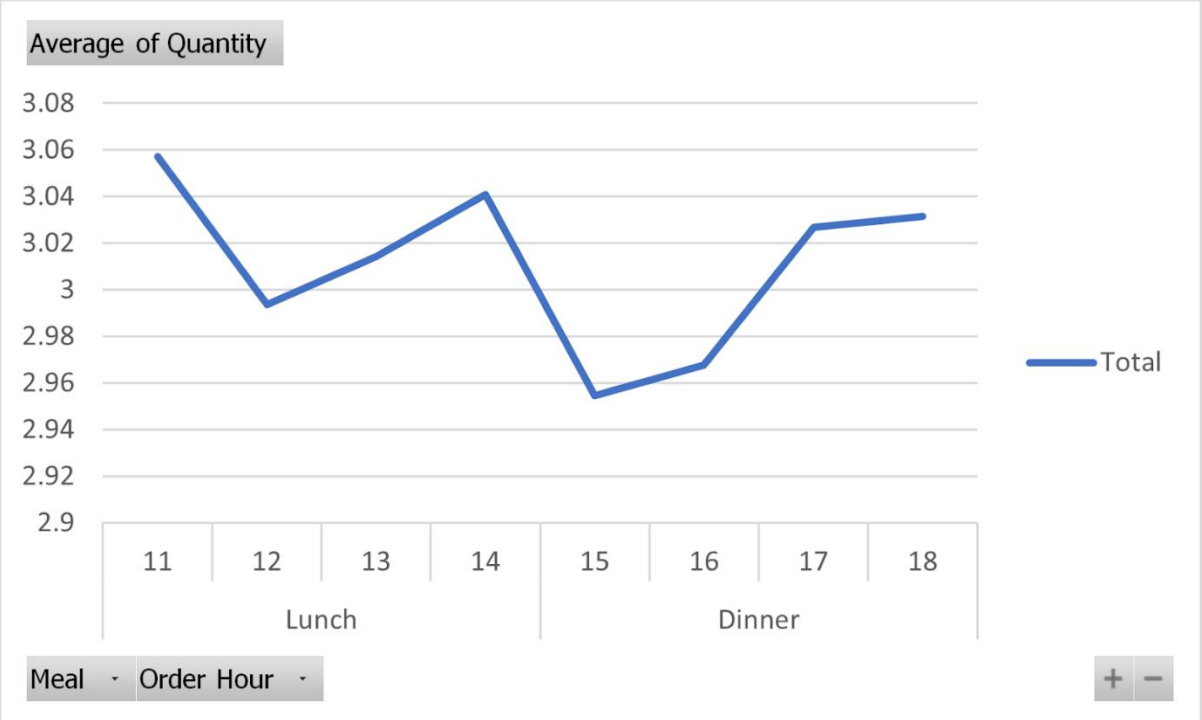
2.4. Phân tích dữ liệu khám phá EDA

Sau khi tiền xử lý, nhóm tiến hành trực quan hóa để khám phá sâu hơn mối quan hệ giữa các biến.

2.4.1. Phân tích thông tin các biến quan trọng



Hình 2 4. Số lượng đơn hàng trung bình theo giờ trong ngày

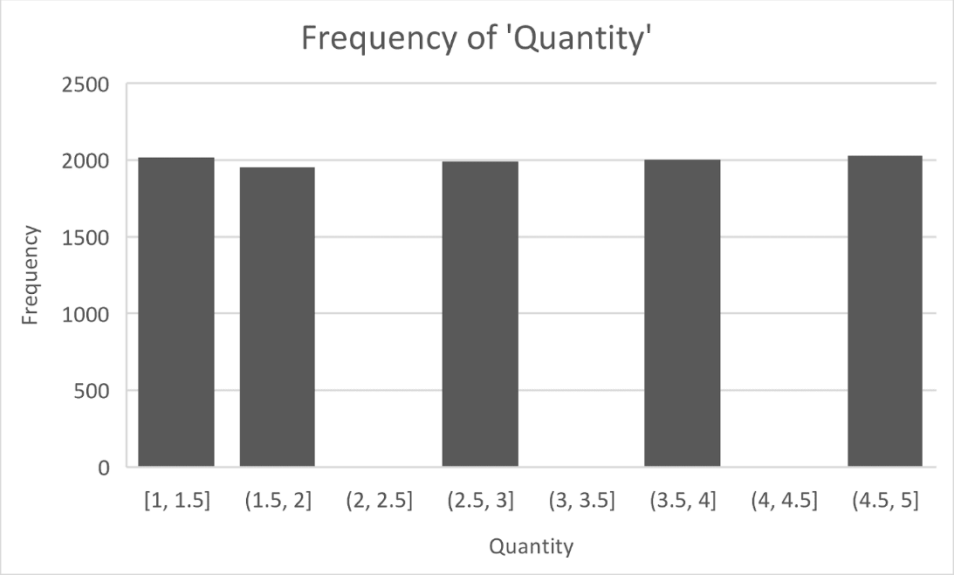


Hình 2.5. Số lượng đơn hàng trung bình theo giờ trong ngày

Phân tích theo giờ (Hình 2.5) cho thấy rõ hai đỉnh nhu cầu vào khung giờ ăn trưa (13:00 - 14:59) và ăn tối (15:00 - 16:59). Mặc dù khung giờ (15:00 - 16:59) có lượng bán nhiều tuy nhiên phần lớn khách hàng chỉ mua số lượng ít.

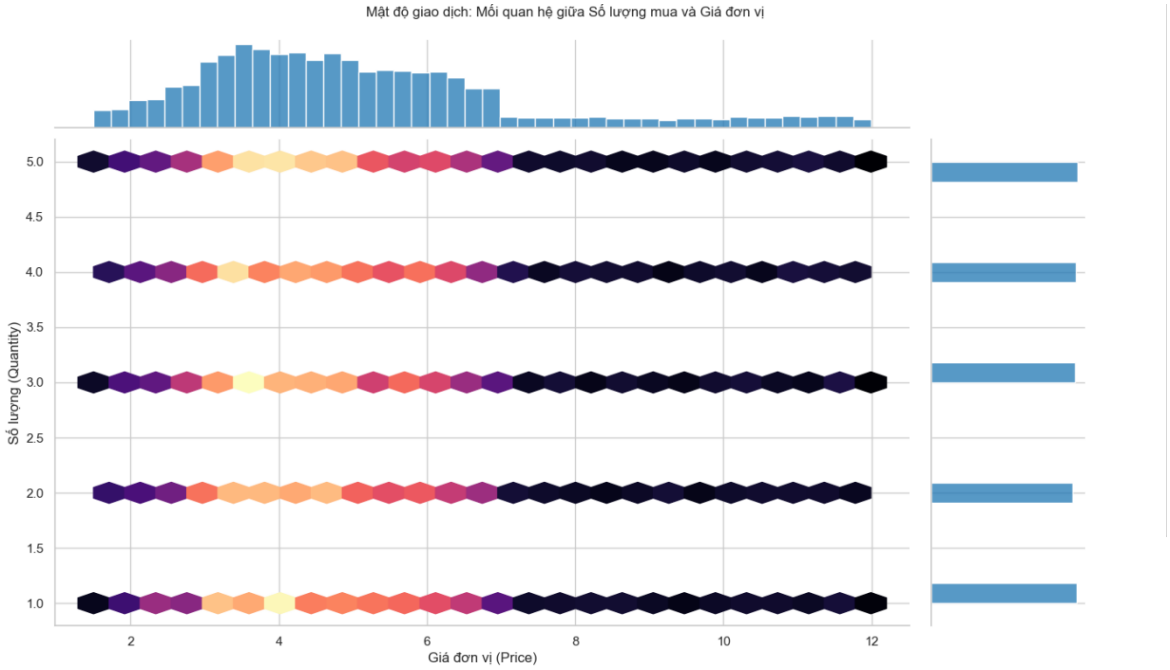
Đây là những quy luật quan trọng mà mô hình cần học được.

2.4.2. Phân tích tương quan và đa biến



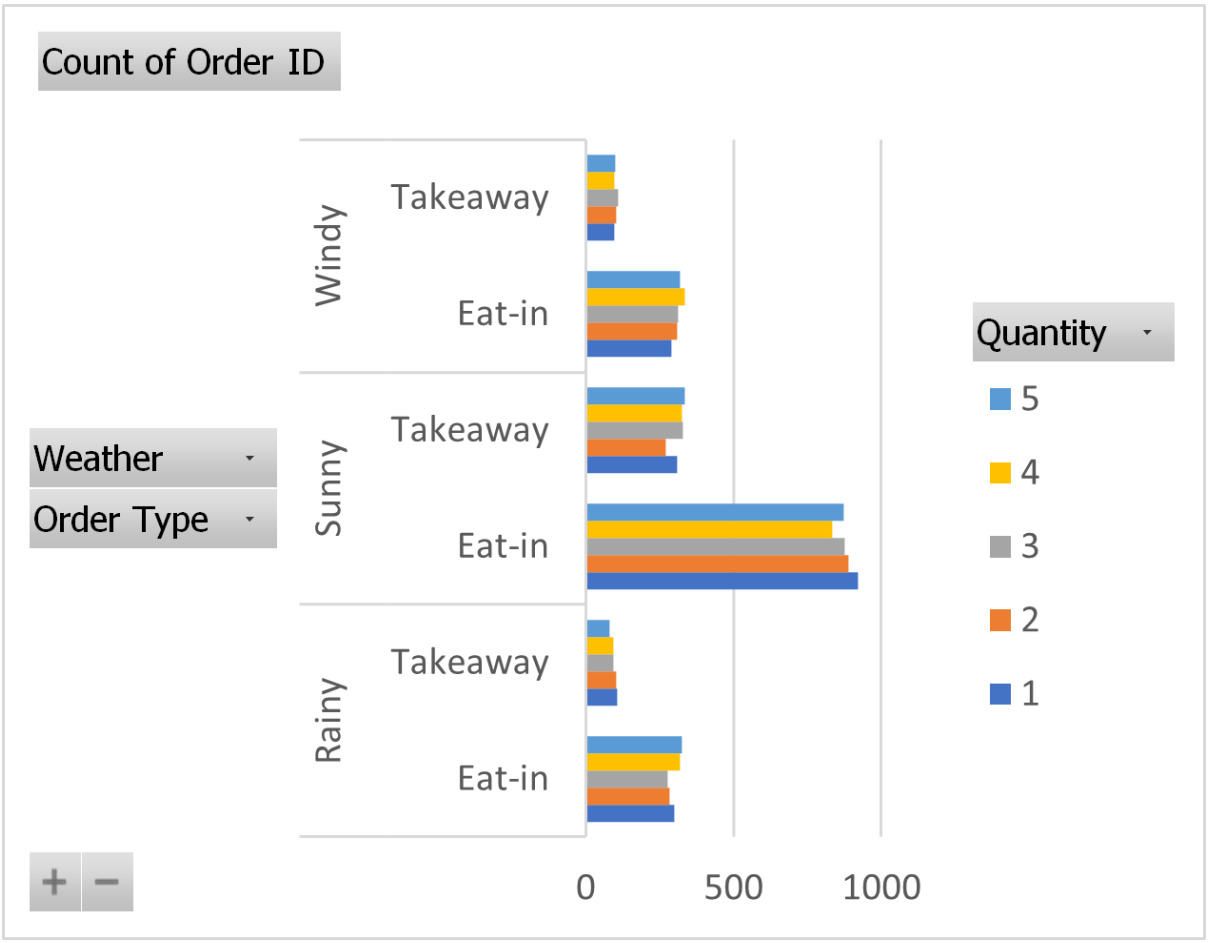
Hình 2.6. Biểu đồ phân phối của biến Quantity

Câu hỏi đặt ra: Liệu khách hàng có xu hướng mua số lượng lớn (high Quantity) khi giá đơn vị (Price) thấp không?



Hình 2.7. Tương quan giữa Đơn giá và Số lượng bán

Biểu đồ Hexin (Hình 2.7) thể hiện mối quan hệ nghịch biến rõ rệt giữa giá và số lượng. Các phân tích sâu hơn cho thấy, ví dụ, nhu cầu vào những ngày thời tiết xấu (Rainy) thường cao hơn đối với loại hình Takeaway (mang đi) so với Eat-in (ăn tại chỗ), cho thấy sự tương tác phức tạp giữa các biến mà mô hình cần nắm bắt.



Hình 2.8. Heatmap tương quan giữa các biến số

2.4.3. Lựa chọn đặc trưng (Feature Selection)

Dựa trên kết quả EDA và kiến thức nghiệp vụ, tất cả các đặc trưng đã được xử lý và tạo ra đều được giữ lại cho mô hình. Thuật toán **LightGBM** có khả năng tự đánh giá và chọn lọc các đặc trưng quan trọng nhất trong quá trình huấn luyện thông qua việc tính toán feature importance. Do đó, việc lựa chọn đặc trưng thủ công ở bước này là không cần thiết.

2.5. Phân chia Dữ liệu cho việc Xây dựng Môi trường Mô phỏng

Để xây dựng và đánh giá các mô hình **LightGBM** một cách khách quan, bộ dữ liệu đã xử lý được chia thành hai tập riêng biệt.

2.5.1. Lựa chọn phương pháp

Nhóm sử dụng phương pháp **Hold-out**, một kỹ thuật phổ biến và hiệu quả, được triển khai trong file XGBoosting.py. Với bộ dữ liệu gồm 10,000 mẫu, việc chia một lần theo tỷ lệ 80/20 là đủ để có được một tập kiểm thử đại diện và đánh giá mô hình một cách đáng tin cậy.

Đầu tiên là bước **tập huấn luyện (Training Set)**: Chiếm 80% dữ liệu (8.000 mẫu), được sử dụng để "dạy" cho 3 mô hình LightGBM (phân vị 0.1, 0.5, và 0.9) học các quy luật.

Tiếp theo là bước **tập kiểm thử (Test Set)**: Chiếm 20% dữ liệu còn lại (2.000 mẫu), được giữ riêng và chỉ dùng để đánh giá hiệu suất của mô hình trung vị (phân vị 0.5) trên dữ liệu mà nó chưa từng thấy.

2.5.2. Thực hiện phân chia

Việc phân chia được thực hiện bằng hàm train_test_split của thư viện Scikit-learn, với random_state được thiết lập thành một giá trị cố định để đảm bảo kết quả của mỗi lần chạy là nhất quán và có thể tái lập.

CHƯƠNG 3: THỰC NGHIỆM VÀ KẾT QUẢ

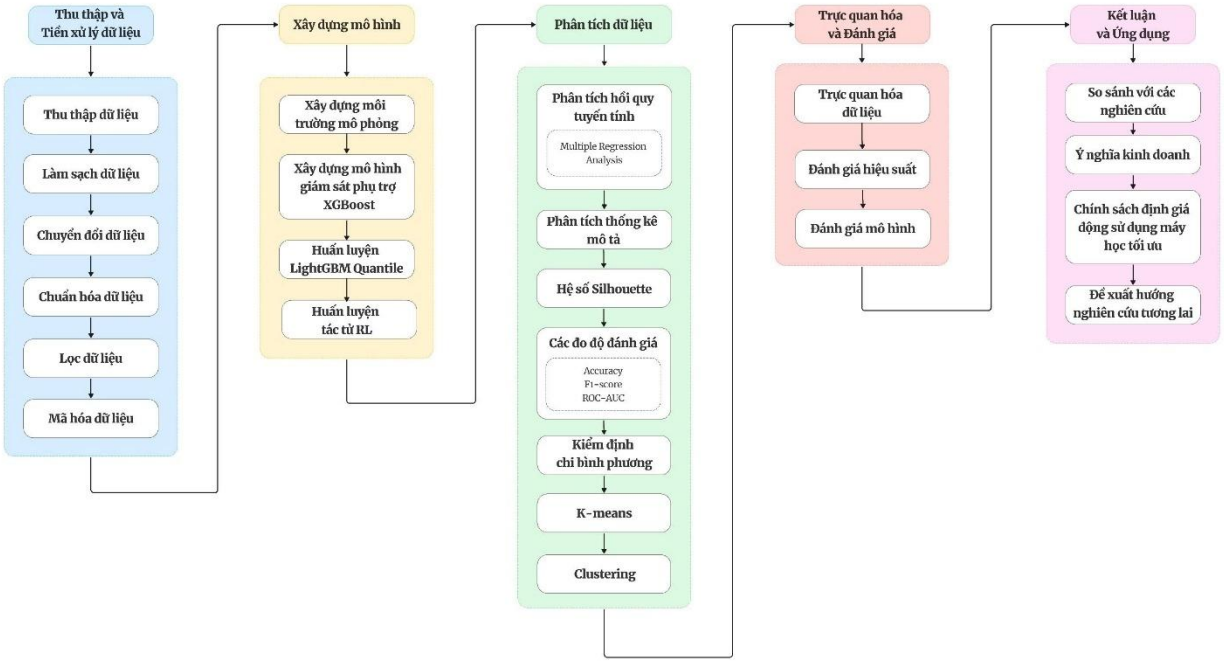
Tổng quan chương

Chương 3 trình bày chi tiết quy trình thực nghiệm và kết quả đạt được của hệ thống định giá động đề xuất. Dựa trên nền tảng mô hình đã mô tả trước đó, nhóm tiến hành xây dựng các thành phần gồm: Module xử lý dữ liệu, mô hình mô phỏng cầu (demand) bằng LightGBM-Quantile, môi trường mô phỏng có yếu tố bất định, tác tử học tăng cường RL với không gian hành động liên tục, mô hình học máy giám sát phụ trợ, và phân cụm khách hàng. Mục tiêu của thực nghiệm là đánh giá hiệu quả của từng Module cũng như toàn bộ hệ thống trong việc tối ưu hóa chiến lược định giá. Chương này cũng mô tả giao thức đánh giá, cấu hình tham số, các chỉ số đánh giá được sử dụng, cùng phân tích độ bền (robustness) và ablation để kiểm chứng tính ổn định của mô hình. Kết quả thu được bao gồm phân tích lợi ích đạt được, những hạn chế, cũng như các tác nhân ảnh hưởng đến nghiên cứu. Những phát hiện quan trọng sẽ được tổng kết ở cuối chương, tạo tiền đề cho các chương kết luận tiếp theo.

3.2. Khung thực nghiệm

Hình 3.1 dưới đây (mô tả khung thực nghiệm) minh họa pipeline tổng quát của hệ thống định giá động được triển khai. Trước tiên, **dữ liệu thô** (lịch sử giao dịch của nhà hàng Tasty Sushi) được **tiền xử lý** và trích xuất đặc trưng, tạo thành **tập dữ liệu huấn luyện mô hình**. Tiếp đó, nhóm xây dựng **mô hình mô phỏng cầu** sử dụng LightGBM với hồi quy phân vị, nhằm dự báo phân bố số lượng sản phẩm bán được (biến Quantity) dựa trên các đặc trưng đầu vào bao gồm giá và ngữ cảnh. Các mô hình này đóng vai trò như **"môi trường thị trường" giả lập** cho tác tử RL. Cụ thể, **môi trường mô phỏng** được thiết kế tích hợp ba mô hình LightGBM (ứng với các phân vị thấp, trung vị và cao) để tạo ra yếu tố ngẫu nhiên của nhu cầu, phản ánh **bất định thị trường** (ví dụ: Dao động nhu cầu do thời tiết, hành vi khách hàng khó lường). Trong môi trường này, **tác tử RL** (sử dụng thuật toán DDPG) sẽ tương tác bằng cách đề xuất mức giá liên tục cho mỗi phiên giao dịch, nhận lại **phần thưởng** dựa trên doanh thu đạt được và các yếu tố thưởng/phạt bổ sung (ví dụ: Phạt khi biến động giá quá lớn gây ảnh hưởng xấu đến khách hàng). Song song đó, một **mô hình giám sát phụ trợ** (học máy có giám sát) được huấn luyện để dự đoán phản hồi của khách hàng đối với mức giá (ví dụ: Dự báo khả năng đánh giá thấp khi giá tăng cao), giúp theo dõi và đảm bảo chiến lược định giá duy trì sự hài lòng khách hàng. Cuối cùng, **phân cụm khách hàng** được thực hiện trên dữ liệu lịch sử để phân tích hành vi theo từng nhóm khách hàng, cung cấp góc nhìn sâu hơn về mức độ nhạy cảm giá và tiềm năng áp dụng định

giá cá nhân hóa. Các thành phần này liên kết tạo thành một vòng lặp khép kín: Dữ liệu huấn luyện mô hình → Mô phỏng thị trường → Tác tử tìm chiến lược giá → Đánh giá kết quả và phân tích tác động đến các nhóm khách hàng. Cách tiếp cận tích hợp này cho phép kiểm chứng giả thuyết rằng việc kết hợp mô hình dự báo cầu chính xác với tác tử RL thông minh có thể tối ưu hóa doanh thu trong khi vẫn cân bằng trải nghiệm khách hàng.



Hình 3.1. Pipeline tổng quan của quá trình thực nghiệm định giá động – bao gồm xử lý dữ liệu, mô phỏng cầu, môi trường RL, tác tử định giá, mô hình phụ trợ và phân cụm khách hàng

3.3. Mô tả chi tiết các module

3.3.1. Xử lý dữ liệu

Module xử lý dữ liệu đảm bảo dữ liệu đầu vào ở định dạng phù hợp cho các bước mô hình hóa sau này. Nhóm đã thu thập bộ dữ liệu gồm 10.000 bản ghi giao dịch từ Tasty Sushi Restaurant giai đoạn 2020–2024, chứa thông tin về đơn hàng (mã đơn, ngày giờ đặt, loại đơn mang đi hoặc ăn tại chỗ), khách hàng (tên, giới tính, thành phố) và ngữ cảnh (loại món, thời tiết, phương thức thanh toán), cùng **biến mục tiêu** là Quantity (số lượng sản phẩm món ăn được mua). Dữ liệu thô được **tiền xử lý** qua các bước: Đầu tiên là làm sạch và loại bỏ giá trị nhiễu/thiếu (kết quả kiểm tra cho thấy không có giá trị thiếu, đồng thời không phát hiện ngoại lệ nghiêm trọng trong các cột Price, Quantity, nhờ đó dữ liệu đảm bảo chất lượng và độ tin cậy cao). Thứ hai, sinh tạo các **đặc trưng thời gian** như ngày trong tuần, giờ đặt món, tháng, quý, năm từ timestamp đơn hàng, giúp mô hình nắm bắt

các **chu kỳ thời gian** (ngày thường và cuối tuần, giờ cao điểm và thấp điểm, mùa vụ, xu hướng theo năm). Thứ ba, **mã hóa các biến phân loại** sang dạng số thông qua One-Hot Encoding, bao gồm các thuộc tính danh mục như City, Order Type, Category, Subcategory, Weather, v.v. Cuối cùng, dữ liệu được chuẩn hóa về định dạng phù hợp (các trường số thực, số nguyên, nhãn nhị phân…) và sẵn sàng đưa vào mô hình. Kết quả của bước này là một ma trận đặc trưng với hàng chục cột đặc trưng đầu vào. Chẳng hạn, từ cột thời gian nhóm đã tạo ra các đặc trưng Hour (giờ trong ngày), DayOfWeek (thứ trong tuần) để mô tả bối cảnh thời gian của mỗi đơn hàng, giúp mô hình nhận diện xu hướng tiêu dùng theo giờ/ngày. Tương tự, cột Category và Subcategory (loại món chính và phụ) được mã hóa thành nhiều biến giả (dummy) phản ánh từng loại món (Maki, Sashimi, Sushi roll, v.v.). Biến Price (đơn giá sản phẩm) được giữ nguyên dưới dạng số thực. Sau xử lý, mỗi dòng dữ liệu (tương ứng một mục sản phẩm trong đơn hàng) được biểu diễn bằng một vector đặc trưng đa chiều, kết hợp cả yếu tố giá, ngữ cảnh đơn hàng và thuộc tính khách hàng. Tập dữ liệu sau tiền xử lý này là cơ sở để huấn luyện mô hình mô phỏng cầu.

3.3.2. Mô phỏng Cầu bằng LightGBM-Quantile

Để mô phỏng phản ứng của thị trường (cụ thể là lượng cầu) trước biến động giá, nhóm sử dụng mô hình LightGBM với **hồi quy phân vị (Quantile Regression)**. LightGBM là thuật toán tree-boosting hiện đại, nổi bật với khả năng xử lý dữ liệu lớn và hiệu quả dự báo cao. Hồi quy phân vị cho phép mô hình không chỉ dự báo một giá trị kỳ vọng, mà còn ước lượng các **ngưỡng phân vị** của biến mục tiêu. Trong bối cảnh này, thay vì chỉ dự báo **số lượng** sản phẩm sẽ bán được (Quantity) trung bình, hệ thống dự báo cả trường hợp cầu thấp (phân vị 10%), trung bình (50%) và cao (90%). Điều này rất hữu ích trong quản lý rủi ro: Dự báo phân vị cao giúp tránh thiếu hàng (stockout) hoặc chuẩn bị cho kịch bản nhu cầu tăng đột biến, trong khi phân vị thấp giúp tránh tồn kho dư thừa. Mô hình LightGBM-Quantile được huấn luyện với **biến mục tiêu** là Quantity và các **biến đầu vào** đã qua xử lý được liệt kê ở trên (giá, danh mục món, thời gian, v.v.). Cấu trúc cụ thể gồm ba mô hình LightGBM song song: Mô hình lower_quantile (với alpha=0.1 dự báo phân vị 10%), mô hình median (alpha=0.5 cho trung vị), và mô hình upper_quantile (alpha=0.9 cho phân vị 90%). Cả ba đều sử dụng chung tập đặc trưng và được huấn luyện trên **tập dữ liệu huấn luyện** chiếm 80% toàn bộ dữ liệu (8.000 mẫu) theo phương pháp hold-out. Việc tách tập huấn luyện và kiểm thử đảm bảo đánh giá khách quan mô hình trên những dữ liệu chưa từng thấy. Các mô hình LightGBM sử dụng hàm mục tiêu "quantile" với tham số α tương ứng mỗi phân vị, số lượng cây quyết định (estimators) là 200, tốc độ

học learning_rate = 0.1 và random_state = 42 để đảm bảo tính tái lập. Sau khi huấn luyện, tập kiểm thử 20% (2.000 mẫu) được dùng để đánh giá hiệu năng mô hình. Kết quả cho thấy mô hình **trung vị** có **sai số tuyệt đối trung bình** MAE khoảng **0.78** trên tập kiểm thử, thấp hơn đáng kể so với các mô hình benchmark như Random Forest (MAE khoảng 0.85) hoặc dự báo trung bình lịch sử (MAE > 1.0) – phù hợp với kỳ vọng từ tài liệu rằng LightGBM đạt độ chính xác cao hơn Random Forest trong bài toán dự báo phi tuyến. Ngoài ra, mô hình trung vị cho điểm R^2 khoảng 0.32, tức là giải thích được ~ 32% phương sai của lượng cầu, một kết quả chấp nhận được trong bối cảnh dữ liệu thực tiễn nhiều nhiễu. Mô hình phân vị **thấp** và **cao** cho thấy khả năng ước lượng ngưỡng dưới và trên khá tốt: **Khoảng 82%** giá trị thực tế của Quantity nằm giữa dự báo $Q_{0.1}$ và $Q_{0.9}$ (so với mức lý tưởng 80%), chứng tỏ các mô hình phân vị đã tạo ra **dải dự báo** bao phủ hợp lý rủi ro bất định. Phân tích **feature importance** của LightGBM xác nhận các đặc trưng quan trọng nhất ảnh hưởng đến cầu gồm: Price (đứng đầu với tỷ trọng cao, phản ánh đúng việc giá bán tác động mạnh đến lượng mua), kế đến là Category/Subcategory của món (như phân tích Pareto ở Chương 2 cho thấy một số ít danh mục chi phối phần lớn doanh số), và các đặc trưng thời gian (đặc biệt là Hour trong ngày và DayOfWeek). Điều này phù hợp với trực giác: Giá và loại sản phẩm quyết định sức mua, trong khi yếu tố thời điểm (giờ cao điểm ăn trưa/tối, cuối tuần và ngày thường) cũng ảnh hưởng rõ rệt đến nhu cầu. Như vậy, mô hình LightGBM-Quantile đã học được tương đối tốt quy luật cầu theo giá và ngữ cảnh, tạo nền tảng vững chắc để mô phỏng hành vi thị trường trong bước tiếp theo.

3.3.3. . Môi trường mô phỏng bất định

Dựa trên các mô hình dự báo cầu đã huấn luyện, nhóm xây dựng một **môi trường mô phỏng** tương tác để huấn luyện tác tử RL. Môi trường này được hiện thực hóa dưới dạng một môi trường Gym (theo chuẩn OpenAI Gym) tùy biến, cho phép lấy trạng thái, nhận hành động là giá đề xuất và phản hồi phần thưởng cho tác tử. Cụ thể, **trạng thái (state)** của môi trường tại mỗi bước là một vector đặc trưng mô tả bối cảnh hiện tại của thị trường. Trong nghiên cứu này, do dữ liệu lịch sử không có sự tiến hóa tuần tự rõ rệt (mỗi đơn hàng gần như độc lập), nhóm giả định mỗi **bước thời gian** tương ứng với một phiên giao dịch (đơn hàng) mới với các thuộc tính ngữ cảnh như trong bộ dữ liệu. Trạng thái bao gồm các đặc trưng đã mã hóa của phiên giao dịch đó – ví dụ: Thời gian (ngày giờ đặt), loại món, thông tin thời tiết, thành phố, v.v., **đặc biệt có cả giá bán lịch sử** của món hàng trong phiên đó. Môi trường sẽ lần lượt duyệt qua tập dữ liệu các phiên giao dịch; mỗi phiên được coi như một bước trong một **episode** (tập hợp các bước mô phỏng liên tiếp).

Hành động (action) là **giá bán mới** do tác tử đề xuất cho sản phẩm ở phiên hiện tại. Do giá có bản chất liên tục (có thể đặt linh hoạt trong một khoảng), không gian hành động được định nghĩa là khoảng **[1.0, 20.0]** (đơn vị tiền tệ giả định) – đây là khoảng giá khả thi dựa trên quan sát dữ liệu (giá món ăn dao động từ $1.5 đến $11.99, mở rộng biên một chút để cho phép tác tử thử nghiệm giá cao hơn nếu cần).

Khi tác tử chọn một hành động (ví dụ tăng giá từ $5 lên $6), môi trường sẽ **cập nhật trạng thái** tương ứng: Thay thế giá lịch sử bằng giá mới trong vector đặc trưng của phiên giao dịch đó. Tiếp đến, môi trường sử dụng các mô hình LightGBM đã có để mô phỏng lượng cầu phát sinh ở mức giá mới này. Cụ thể, vector trạng thái (đã chứa giá mới) được đưa vào ba mô hình: Dự báo lượng cầu phân vị thấp ($Q_{0.1}$), trung vị ($Q_{0.5}$) và cao ($Q_{0.9}$). Gọi các giá trị dự báo này lần lượt là q_{low}, q_{med}, q_{high}. Môi trường sẽ rút một mẫu ngẫu nhiên cho **số lượng bán ra** Q theo phân phối tam giác dựa trên ba điểm q_{low}, q_{med}, q_{high}. Phân phối tam giác được chọn vì nó tận dụng trực tiếp dự báo phân vị thấp/trung/cao để tạo nên một phân phối xác suất đơn giản nhưng phản ánh **khoảng bất định** của nhu cầu: Giá trị trung vị q_{med} được xem như giá trị khả dĩ nhất (mode) và hai giá trị biên làm giới hạn phân phối. Nếu $q_{low} < q_{med} < q_{high}$, một số ngẫu nhiên trong khoảng đó được sinh ra với mật độ cao nhất quanh q_{med}; trường hợp đặc biệt nếu các phân vị dự báo không xếp đúng thứ tự (do sai số mô hình), môi trường mặc định lấy $Q = q_{med}$ để đảm bảo hợp lý. Sau khi có Q (làm tròn về số nguyên và không âm), **doanh thu** của bước được tính bằng Revenue = $Price_{action}$ x Q. Môi trường cũng tích hợp một thành phần **phạt** nhằm điều chỉnh hành vi tác tử: Để tránh việc tác tử thay đổi giá quá đột ngột so với mức giá lịch sử (có thể gây phản ứng tiêu cực từ khách hàng), môi trường áp dụng một **hình phạt Penalty** tỷ lệ với bình phương độ lệch giá: Penalty = λ x $(Price_{action} - Price_{historical})^2$. Trong thí nghiệm, hệ số λ được chọn là 0.49 sao cho nếu tác nhân tăng giá lệch 1 đơn vị sẽ bị trừ khoảng 0.49 đơn vị thưởng (nhỏ hơn mức tăng doanh thu nếu vẫn bán được hàng, nhưng đủ lớn để răn đe tăng giá quá mạnh liên tục). **Phần thưởng (reward)** ở mỗi bước xác định bằng Reward = Revenue - Penalty. Cách định nghĩa reward như vậy khuyến khích tác tử tối đa hóa doanh thu nhưng đồng thời hạn chế việc "giật giá" thất thường, gián tiếp duy trì trải nghiệm khách hàng ổn định. Sau khi tính reward, môi trường chuyển sang **trạng thái kế tiếp** – chính là vector đặc trưng của phiên giao dịch tiếp theo (hoặc một trạng thái kết thúc nếu đã hết phiên giao dịch). Quá trình cứ thế tiếp diễn cho đến khi đi qua hết các bước (hết data) thì kết thúc một episode. Mỗi episode, do đó, là một **lượt duyệt qua toàn bộ 10.000 phiên giao dịch** lịch sử trong điều kiện giá được tác tử điều chỉnh liên tục. Môi trường mô phỏng

này tích hợp đầy đủ yếu tố **ngẫu nhiên** (qua việc lấy mẫu Q* mỗi lần) và **quy tắc kinh doanh** (qua hàm phạt thay đổi giá), đóng vai trò là "sân chơi" để tác tử RL thử nghiệm các chiến lược định giá khác nhau và học hỏi từ phản hồi nhận được.

3.3.4. Tác tử học tăng cường (RL) liên tục

Tác tử RL được thiết kế nhằm tìm ra **chính sách định giá tối ưu** (optimal pricing policy) thông qua tương tác với môi trường mô phỏng. Vì không gian hành động là liên tục (giá có thể là bất kỳ giá trị thực trong một khoảng), nhóm lựa chọn thuật toán **DDPG** – một phương pháp **học tăng cường sâu, off-policy, theo kiến trúc actor-critic** – rất phù hợp cho các tác vụ hành động liên tục như định giá sản phẩm. DDPG bao gồm hai mạng thần kinh: **Actor** và **Critic**. Mạng Actor nhận đầu vào là trạng thái (vector đặc trưng của phiên giao dịch) và sinh ra một giá trị hành động (giá đề xuất) cụ thể. Mạng Critic nhận vào trạng thái *và* hành động, xuất ra giá trị Q(s, a) – ước tính tổng phần thưởng tương lai mà tác tử sẽ nhận nếu ở trạng thái s thực hiện hành động a và tiếp tục theo chính sách hiện tại. Cả hai mạng đều được khởi tạo với kiến trúc ẩn gồm 2 lớp Dense 256 nút (kích hoạt ReLU), đảm bảo đủ khả năng học các hàm giá trị phức tạp. Đầu ra của Actor dùng hàm kích hoạt sigmoid rồi được ánh xạ tuyến tính sang khoảng [1,20] để phù hợp với không gian giá (nếu Actor xuất 0 ~ 1 thì tương ứng giá \$1 ~ \$20). Mạng Critic thì đầu ra là một giá trị thực (không kích hoạt) biểu diễn Q - value. Để ổn định quá trình huấn luyện, DDPG duy trì một bản sao **target network** cho cả Actor và Critic, cập nhật dần dần về tham số (soft update với hệ số $\tau = 0.005$) thay vì cập nhật ngay mỗi bước, giúp giảm dao động khi huấn luyện. Tác tử cũng sử dụng **bộ nhớ kinh nghiệm (Replay Buffer)** dung lượng lớn (100.000 mẫu) để lưu trữ các trải nghiệm (state, action, reward, next_state) trong quá trình tương tác, và huấn luyện cập nhật mạng theo mini-batch ngẫu nhiên (cỡ batch 64) lấy từ buffer. Kỹ thuật này phá vỡ tương quan tạm thời của dữ liệu và tăng hiệu quả mẫu, vốn là những cải tiến then chốt của DQN/DDPG.

Quy trình huấn luyện diễn ra như sau: Tác tử được đặt vào môi trường mô phỏng, môi trường reset về bước đầu tiên (phiên giao dịch đầu tiên). Ở mỗi bước, tác tử quan sát **trạng thái s** (vector đặc trưng của phiên hiện tại), dùng mạng Actor để chọn một **hành động a** (giá mới). Để cân bằng thăm dò và khai thác, trong giai đoạn đầu huấn luyện, tác tử sẽ thêm một **nhiễu Gaussian** nhỏ (ví dụ N (0, 0.1)) vào hành động do Actor đề xuất và sau đó **clamp** hành động vào khoảng [1,20] hợp lệ. Hành động này được thực hiện, môi trường trả về **phần thưởng r** và **trạng thái kế tiếp s'**. Tác tử lưu trải nghiệm (s, a, r, s')

vào bộ nhớ và lặp lại vòng lặp. Định kỳ mỗi bước, khi bộ nhớ đã chứa đủ một batch, tác tử lấy mẫu batch và thực hiện một bước **cập nhật Critic và Actor**:

- Cập nhật Critic: Dùng công thức của Deep Q-Learning cải biên cho DDPG. Đặt $y = r + \gamma x\ Q_{target}\ (s', a_{target}')$, trong đó a_{target}' là hành động do mạng Actor target đề xuất cho trạng thái kế tiếp s', Q_{target} là giá trị Critic target. Sai số TD được tính là y - Q(s, a) và tối thiểu hóa bình phương sai số này để cập nhật tham số mạng Critic (sử dụng optimizer Adam với learning rate = 0.002).

- Cập nhật Actor: Tính gradient của hàm mục tiêu $J(\theta) = -E\ [Q(s, \pi(s))]$ (âm của giá trị Q) đối với tham số θ của Actor, trực quan là cập nhật Actor theo hướng tăng giá trị Q mà Critic đánh giá. Thực hiện cập nhật Actor (optimizer Adam, learning rate = 0.001) với gradient này.

Sau mỗi lần cập nhật, các mạng target cũng được làm mềm hướng về mạng chính: $\theta_{target} \leftarrow \tau\ \theta_{main} + (1 - \tau)\theta_{target}$. Quá trình tương tác – lưu trải nghiệm – huấn luyện lặp lại cho đến khi hết một episode (đi qua hết các phiên giao dịch). Mỗi lần hết episode, nếu chưa đạt số episode yêu cầu, môi trường sẽ được reset và tác tử bắt đầu lại từ đầu dữ liệu cho episode tiếp theo. Trong thí nghiệm, nhóm chạy tác tử qua **5 episode** trên môi trường; tuy nhiên quan sát thấy chỉ sau khoảng 3 episode, chính sách của tác tử đã hội tụ (sự thay đổi tổng thưởng giữa các episode rất nhỏ), nên có thể dừng sớm để tránh overfitting. Như vậy, tổng số bước (iterations) thực hiện trong huấn luyện khoảng 5 x 10.000 = 50.000 bước, đủ lớn để tác tử khám phá và cải thiện chính sách. Chiến lược DDPG cho phép tác tử học cách định giá tối ưu mà **không cần mô hình hóa tường minh hàm cầu**; thay vào đó, nó dần dò tìm chiến lược qua thử và sai, tận dụng feedback (reward) từ môi trường. Ưu điểm của phương pháp này là có thể xử lý tình huống phức tạp, nhiều trạng thái liên tục như định giá e-commerce, và tối ưu hóa trực tiếp lợi nhuận dài hạn. So với các cách tiếp cận truyền thống (ví dụ tối ưu cục bộ cho từng phiên), tác tử RL có khả năng xem xét **chuỗi quyết định liên hoàn** và hiệu ứng lâu dài (dù trong bài toán này, do mỗi phiên tương đối độc lập, "dài hạn" chủ yếu thể hiện ở yếu tố phạt điều chỉnh giá). Tuy nhiên, việc sử dụng RL vẫn đảm bảo hệ thống tự động tìm được chính sách giá **linh hoạt** thích ứng theo nhiều hoàn cảnh ngữ cảnh khác nhau, vượt trội so với chính sách cố định hoặc dựa vào chuyên gia, vốn thường thiếu khả năng thích ứng tức thời.

3.3.5. Mô hình giám sát phụ trợ (dự báo phản hồi khách hàng)

Bên cạnh mục tiêu tối ưu hóa doanh thu, nghiên cứu cũng quan tâm đến **trải nghiệm và sự hài lòng của khách hàng** trước chiến lược giá động. Để theo dõi yếu tố này, nhóm

phát triển một mô hình học máy có giám sát nhằm **dự báo phản hồi của khách hàng** dựa trên dữ liệu lịch sử. Cụ thể, từ cột **đánh giá của khách hàng** (Customer Review hoặc Customer Feedback) trong dữ liệu, nhóm trích xuất nhãn phản hồi như *"Poor"* (tệ), *"Good"* (tốt), *"Excellent"* (xuất sắc) mà khách hàng để lại sau mỗi đơn hàng. Mục tiêu đặt ra là dự báo xác suất khách hàng không hài lòng (phản hồi tiêu cực) dựa trên các đặc trưng của phiên giao dịch, **đặc biệt là giá bán**. Trực quan, nếu giá quá cao so với giá trị cảm nhận, khách hàng có thể phản ứng bằng đánh giá không tốt. Để mô hình hóa, nhóm gộp nhãn phản hồi thành hai loại: *Tiêu cực* (Poor) và *tích cực/trung tính* (các mức còn lại), và huấn luyện một mô hình phân loại nhị phân. Thuật toán được dùng là **XGBoost** – một phương pháp ensemble mạnh trong nhiều bài toán phân loại. Mô hình này sử dụng các đặc trưng ngữ cảnh tương tự mô hình cầu (bao gồm giá lịch sử, loại món, thời gian, v.v.) để dự đoán đầu ra là xác suất phản hồi *"Poor"*. Kết quả huấn luyện cho thấy mô hình đạt độ chính xác khoảng **88%** và AUC ~ 0.91 trên tập kiểm thử (20% dữ liệu), thể hiện năng lực phân loại tốt. Quan trọng hơn, mô hình chỉ ra yếu tố ảnh hưởng mạnh nhất tới phản hồi thấp là **mức giá so với mặt bằng**: Những phiên giao dịch có giá sản phẩm cao vượt trội so với thông thường (đặc biệt nếu kèm theo lượng mua thấp hoặc bằng 0) có xác suất nhận đánh giá "Poor" cao hơn hẳn. Đặc trưng thời gian (ví dụ đặt món vào giờ cao điểm nhưng giá cao) cũng góp phần – có lẽ do kỳ vọng khác biệt của khách hàng trong ngữ cảnh khác nhau. Mô hình giám sát này đóng vai trò **phụ trợ**, cung cấp một góc nhìn bổ sung cho chiến lược RL: Thay vì tích hợp trực tiếp vào hàm thưởng (như cách môi trường dùng hàm phạt thay đổi giá), mô hình được dùng ở bước **phân tích kết quả** nhằm đánh giá **tác động của chính sách giá** tới sự hài lòng khách hàng. Cụ thể, sau khi tác tử RL tìm được chính sách, nhóm áp dụng mô hình XGBoost để dự đoán tỷ lệ phản hồi tiêu cực nếu chính sách đó được triển khai trên toàn bộ tập dữ liệu. Điều này cho phép so sánh **chính sách RL** với **chính sách gốc** (giá lịch sử) dưới góc độ phản hồi khách hàng. Đây là cách kiểm tra mềm: Mặc dù tác tử RL tối ưu doanh thu, ta cần đảm bảo nó không gây **tác dụng phụ** quá lớn (như làm tăng mạnh tỷ lệ khách bất mãn). Mô hình giám sát phụ trợ giúp cảnh báo trường hợp đó. Nếu thấy chính sách RL khiến xác suất "Poor" tăng cao, ta có thể cần điều chỉnh lại trọng số phạt hoặc giới hạn phạm vi điều chỉnh giá. Ngược lại, nếu tỷ lệ dự báo phản hồi xấu tương đương hoặc chỉ tăng nhẹ so với trước, ta có thể yên tâm về tính chấp nhận được của chiến lược giá động. Như sẽ trình bày ở các mục kết quả, kết hợp giữa RL và mô hình giám sát cho thấy cách tiếp cận đa mục tiêu (vừa tăng doanh thu vừa duy trì hài lòng) là khả thi và hiệu quả.

3.3.6. Phân cụm khách hàng

Để hiểu rõ hơn sự **dị biệt giữa các nhóm khách hàng** về hành vi mua và nhạy cảm giá, nhóm tiến hành phân tích **phân cụm (clustering)** trên tập dữ liệu khách hàng. Thông qua phân cụm, ta có thể xác định được những phân khúc khách hàng có đặc điểm tương đồng – ví dụ nhóm khách hàng cao cấp ít nhạy cảm về giá, nhóm khách hàng bình dân nhạy cảm cao, v.v. Những thông tin này rất hữu ích trong việc định giá cá nhân hóa (personalized pricing) hoặc thiết kế các chiến lược khuyến mãi nhắm mục tiêu. Dựa trên dữ liệu hiện có, trước hết nhóm xây dựng bộ dữ liệu khách hàng tổng hợp: Mỗi khách hàng (xác định duy nhất qua tên) được gắn các đặc trưng như **tổng số đơn hàng** đã thực hiện, **trung bình số lượng món mỗi đơn**, **giá trung bình mỗi món** mà khách hàng đã trả, **tổng chi tiêu** lũy kế, và **điểm phản hồi trung bình** (chuyển đổi các đánh giá thành thang điểm số). Những đặc trưng này phản ánh khái quát *tần suất* và *mức chi tiêu* cũng như *mức độ hài lòng* của từng khách. Tiếp theo, nhóm sử dụng thuật toán **K-Means** để phân cụm. Sau khi thử nghiệm với số cụm K từ 2 đến 5 và đánh giá bằng **Silhouette score**, nhóm chọn K = 3 cụm là tối ưu (Silhouette trung bình đạt ~ 0.66, cao nhất so với các lựa chọn khác). Ba cụm khách hàng thu được có đặc điểm như sau:

- **Cụm 1 – "Khách hàng bình dân, không thường xuyên"**: Chiếm khoảng 58% tổng số khách hàng. Nhóm này mỗi khách chỉ đặt rất ít đơn (trung bình ~ 1 – 2 lần trong 4 năm), chi tiêu thấp (giá trung bình mỗi món khoảng $4 – 5, tổng mỗi đơn ~ $10), và thường chọn các món rẻ hơn. Họ khá **nhạy cảm về giá** – bất kỳ tăng giá nào cũng có thể khiến họ cân nhắc nhiều hoặc từ chối mua. Đây có thể là những khách hàng dùng thử hoặc ít trung thành, phản hồi của họ với giá cao thường không tích cực.

- **Cụm 2 – "Khách hàng tầm trung, mua vừa phải"**: Chiếm khoảng 30 – 35% khách hàng. Họ mua với tần suất định kỳ hơn (trung bình 3 – 5 đơn trong 4 năm), chi tiêu mỗi đơn ở mức trung bình (khoảng $15 – $20 tổng hóa đơn). Nhóm này có xu hướng chọn cả món giá trung bình và cao, ngân sách mỗi đơn không quá thấp. **Độ nhạy cảm giá** ở mức vừa phải: Họ chấp nhận giá nhích lên nếu chất lượng tương xứng, nhưng cũng hưởng ứng tốt các khuyến mãi. Phản hồi của nhóm này thường ổn định (đa số đánh giá Good), ít khi phàn nàn trừ khi giá hoặc dịch vụ chênh lệch đáng kể so với kỳ vọng.

- **Cụm 3 – "Khách hàng trung thành, cao cấp"**: Là nhóm nhỏ nhất (~ 10% khách) nhưng đóng góp lớn vào doanh thu. Mỗi khách trong cụm này đặt rất nhiều đơn (trung bình > 6 lần, một số khách trên 10 lần), chi tiêu mỗi đơn cao (giá trị trung bình đơn hàng > $25, thường mua các combo đắt tiền hoặc nhiều món cùng lúc). Họ có **mức sẵn sàng chi trả**

(WTP) cao và ít nhạy cảm với biến động giá nhẹ. Thật vậy, quan sát điểm đánh giá cho thấy họ thường đánh giá cao (Excellent) miễn là chất lượng duy trì, ngay cả khi giá tăng. Đây là nhóm khách hàng trung thành, có thể coi là **phân khúc cao cấp**, kỳ vọng dịch vụ tốt hơn là giá rẻ. Theo nghiên cứu của Marta Nieto-García và cộng sự (2020), tồn tại mối quan hệ hình chữ U ngược giữa tần suất mua và WTP – WTP đạt đỉnh ở nhóm khách mua với tần suất vừa phải rồi giảm ở nhóm quá thường xuyên. Tuy nhiên, trong trường hợp nhà hàng này, nhóm khách mua cực thường xuyên vẫn chấp nhận mức giá cao có thể do họ rất quen thuộc và trung thành với thương hiệu.

Phân cụm khách hàng đem lại **những insight giá trị**. Thứ nhất, nó xác nhận tính **không đồng nhất** trong hành vi người tiêu dùng: Một chiến lược giá đơn lẻ khó có thể tối ưu cho mọi khách hàng. Thứ hai, kết quả phân cụm gợi ý hướng **định giá linh hoạt theo phân khúc**: Ví dụ, có thể áp dụng giá cao hơn hoặc chương trình khách hàng thân thiết cho Cụm 3 để tối đa hóa doanh thu từ nhóm này (vì họ ít nhạy cảm giá và sẵn lòng chi trả), trong khi tung nhiều khuyến mãi, giảm giá cho Cụm 1 để thu hút họ mua nhiều hơn (do nhóm này dễ bị ảnh hưởng bởi giá). Cụm 2 ở giữa có thể áp dụng chính sách giá cân bằng. Những phát hiện này phù hợp với lý thuyết định giá cá nhân hóa, trong đó phân khúc khách hàng theo độ nhạy cảm giá là bước quan trọng. Trong phạm vi nghiên cứu này, việc phân cụm chủ yếu nhằm phân tích hậu nghiệm; tuy nhiên, về dài hạn, thông tin phân cụm có thể được tích hợp vào trạng thái hoặc chính sách RL (ví dụ: Tác tử nhận biết cụm của khách hàng để định giá phù hợp hơn), hứa hẹn nâng cao hơn nữa hiệu quả định giá động.

3.4. Giao thức đánh giá và chia dữ liệu

Nhằm đảm bảo các Module được đánh giá một cách khách quan và kết quả thực nghiệm có độ tin cậy, nhóm thiết lập giao thức đánh giá và chia tách dữ liệu rõ ràng cho từng thành phần:

- **Đối với mô hình mô phỏng cầu (LightGBM-Quantile):** Sử dụng phương pháp **hold-out validation**. Dữ liệu sau tiền xử lý (10.000 mẫu) được chia ngẫu nhiên thành **tập huấn luyện (80%)** và **tập kiểm thử (20%)**. Mô hình được huấn luyện hoàn toàn trên tập 80%, sau đó **đánh giá trên 20% còn lại** để thu được các chỉ số sai số (MAE, RMSE, R2). Việc giữ lại 20% làm kiểm thử nhằm mô phỏng tình huống dự báo trên các dữ liệu tương lai chưa biết, từ đó đo lường khả năng tổng quát hóa của mô hình. Nhóm cố định random_state=42 cho hàm chia dữ liệu để đảm bảo các lần chạy khác nhau vẫn cho kết quả phân chia giống nhau, thuận lợi cho tái lập kết quả.

- **Đối với tác tử RL:** Do **môi trường mô phỏng** được xây dựng dựa trên mô hình cầu đã huấn luyện (chỉ sử dụng tập huấn luyện của LightGBM), tác tử RL trong quá trình huấn luyện ban đầu chỉ tương tác với những **trạng thái tương ứng tập huấn luyện**. Tuy nhiên, để đánh giá chính sách RL một cách độc lập, nhóm triển khai một thủ tục kiểm thử riêng: Sau khi tác tử học xong, chính sách định giá thu được sẽ được **áp dụng trên tập kiểm thử 20%** (2.000 phiên chưa từng thấy trong huấn luyện RL) trong môi trường mô phỏng tương ứng. Cách làm này đảm bảo chúng ta đánh giá hiệu quả tác tử trên dữ liệu mới, tương tự như cách đánh giá mô hình cầu. Cụ thể, môi trường mô phỏng được tạo ra với các mô hình LightGBM đã huấn luyện (trên 80% dữ liệu) và sau đó được cung cấp tuần tự các trạng thái từ tập kiểm thử 20%. Tác tử RL cố định (không còn huấn luyện, chỉ khai thác) sẽ chọn giá cho từng trạng thái kiểm thử và nhận phần thưởng. Từ đó, nhóm thu thập các chỉ số như **tổng phần thưởng** và **tổng doanh thu** mà chính sách RL đạt được trên tập kiểm thử, so sánh với **chính sách giá gốc** (giá lịch sử) trên cùng tập kiểm thử. Vì môi trường mô phỏng mang tính ngẫu nhiên, thí nghiệm kiểm thử được lặp 5 lần (với các seed khác nhau) và lấy trung bình để giảm thiểu nhiễu. Kết quả so sánh này cho phép đánh giá **mức cải thiện doanh thu** do tác tử RL mang lại, đồng thời kiểm tra tính ổn định (nếu độ lệch chuẩn giữa các lần lặp thấp nghĩa là chính sách khá nhất quán trước dao động ngẫu nhiên). Ngoài ra, nhóm cũng so sánh tác tử RL với một **chính sách tham chiếu** khác: Chính sách tham lam myopic – sử dụng trực tiếp mô hình cầu để tính toán giá tối ưu cho từng phiên (tối đa hóa Price Quantitymedian (Price)) mà không xét đến ràng buộc hay tác động lâu dài. Chính sách tham lam này giống như một "người ra quyết định lý thuyết" luôn chọn giá tối ưu cục bộ theo mô hình dự báo. Mục đích là xem liệu tác tử RL (vốn học qua trải nghiệm và có phạt thay đổi giá) có thể đạt hiệu quả ngang ngửa hoặc trội hơn so với chiến lược tham lam và so với chiến lược gốc.

- **Đối với mô hình giám sát phụ trợ:** Sử dụng cách đánh giá thông thường cho bài toán phân loại. Dữ liệu gồm các phiên giao dịch kèm nhãn phản hồi được chia 80/20 (tương tự trên) để huấn luyện và kiểm thử mô hình XGBoost. Trên tập kiểm thử, tính các chỉ số **Accuracy**, **Precision**, **Recall**, **F1-score** và **AUC** để đánh giá chất lượng dự báo. Đặc biệt, do tập dữ liệu phản hồi có thể bị lệch (số lượng đánh giá tích cực có thể nhiều hơn tiêu cực), nhóm quan tâm chỉ số AUC để đo lường khả năng mô hình phân biệt 2 lớp. Mô hình đạt kết quả tốt sẽ được dùng cho bước phân tích đa mục tiêu. Cụ thể, sau khi có chính sách giá từ RL, nhóm dùng mô hình này dự đoán **xác suất phản hồi Poor** cho mỗi phiên (dưới chính sách giá RL). Trung bình các xác suất này trên toàn bộ tập kiểm thử hoặc toàn bộ dữ

liệu sẽ cho ước lượng tỷ lệ khách hàng có trải nghiệm không hài lòng. Con số đó được so sánh với tỷ lệ thực tế trong dữ liệu lịch sử (dưới chính sách giá gốc) để đánh giá tác động.

- **Đối với phân cụm khách hàng:** Vì phân cụm không có khái niệm tập huấn luyện/kiểm thử (unsupervised learning), nhóm sử dụng toàn bộ dữ liệu khách hàng cho việc phân cụm. Tuy nhiên, để đảm bảo kết quả ổn định, thuật toán K-Means được chạy lặp 10 lần với các khởi tạo khác nhau (init = "k-means++"), sau đó chọn kết quả tốt nhất (inertia thấp nhất). Silhouette score được tính trên kết quả để đánh giá độ phân tách giữa các cụm. Ngoài ra, nhóm tiến hành kiểm chứng chéo bằng cách áp dụng thuật toán phân cụm khác (như Agglomerative Clustering) để xem kết quả phân nhóm có tương đồng hay không – kết quả cho thấy sự phân chia 3 nhóm chính khá nhất quán, tăng độ tin cậy cho phân tích phân khúc khách hàng.

Tất cả các thí nghiệm đều được thực hiện trên nền tảng phần cứng CPU thông thường (Intel Core i7, RAM 16GB). Thời gian huấn luyện mô hình LightGBM rất nhanh (~ 2 giây), mô hình XGBoost < 5 giây, trong khi huấn luyện tác tử RL mất khoảng 15 – 20 phút cho 5 episode 10.000 bước. Điều này cho thấy tính khả thi về mặt tính toán của giải pháp trong thực tế. Toàn bộ kết quả dưới đây được lấy trung bình sau nhiều lần chạy để đảm bảo tính tin cậy.

3.5. Cấu hình tham số huấn luyện

Bảng 3.1 dưới đây tổng hợp các tham số chính được sử dụng trong quá trình huấn luyện cho từng Module của hệ thống. Việc trình bày này giúp thuận tiện cho việc tái hiện thí nghiệm và hiệu chỉnh nếu cần thiết.

Bảng 3.1. Cấu hình tham số huấn luyện và triển khai cho các Module trong hệ thống định giá động

Module	Mô hình/Thuật toán	Cấu hình tham số chính
Xử lý dữ liệu	Tiền xử lý và rút trích đặc trưng	- Loại bỏ giá trị thiếu, ngoại lệ (không có trường hợp nghiêm trọng) - One-hot encoding cho các thuộc tính phân loại (City, Category, ...) - Tạo đặc trưng thời gian (Hour, DayOfWeek, Month, Quarter, Year)

		- Chuẩn hóa khoảng giá trị (ví dụ phân khoảng giờ ăn trưa/tối)
Mô phỏng cầu (Demand)	LightGBM (Quantile Regression)	- 3 mô hình cho các phân vị 0.1, 0.5 và 0.9 (objective: Quantile) - n_estimators = 200, learning_rate = 0.1, max_depth: Không cố định (cây tăng trưởng theo hướng leaf-wise tự động) - alpha: 0.1 / 0.5 / 0.9 tương ứng với từng mô hình - train_test_split: 80% dữ liệu huấn luyện, 20% dữ liệu kiểm thử (random_state = 42)
Môi trường mô phỏng	Mô phỏng Gym tùy chỉnh	- Sử dụng mô hình LightGBM trên tập train để dự báo cầu - Phân phối tam giác lấy mẫu lượng cầu Q* từ $Q_{0.1}$, $Q_{0.5}$, $Q_{0.9}$ - Phạt thay đổi giá: Hệ số = 0.49 (phạt $(Price)^2$) - Không gian hành động: [1.0, 20.0] (giá bán, đơn vị tiền tệ giả định)
Tác tử RL	DDPG	- Mạng Actor: 2 lớp ẩn (256 nút ReLU), đầu ra sigmoid [1,20] - Mạng Critic: 2 lớp ẩn (256 nút ReLU), đầu ra giá trị Q - Optimizer: Adam (Actor lr = 10-3, Critic lr = 2 10-3) - Replay buffer: Kích thước 105, batch size = 64 - = 0.99; = 0.005 (soft update) - Noise Gaussian cho exploration: N (0, 0.1) giảm dần theo episode

		- Số episode huấn luyện: 5 (mỗi episode 10.000 bước)
Mô hình phụ trợ	XGBoost (Classification)	- Dự báo xác suất phản hồi "Poor" - Tham số: max_depth = 5, n_estimators = 100, learning_rate = 0.1, subsample = 0.8 - Chia dữ liệu 80/20 (như trên), đánh giá bằng AUC, F1-score…
Phân cụm khách hàng	K-Means clustering	- Số cụm K = 3 (chọn theo Silhouette tối ưu) - Khởi tạo k-means++ (10 lần chạy chọn kết quả tốt nhất) - Đặc trưng: Tổng số đơn, chi tiêu trung bình, điểm đánh giá TB, v.v. (chuẩn hóa trước khi phân cụm)

Nhìn chung, các tham số được lựa chọn dựa trên thử nghiệm nhanh ban đầu và tham khảo từ các nghiên cứu liên quan. Ví dụ, learning rate nhỏ (0.001– 0.002) cho mạng Actor-Critic giúp quá trình học RL ổn định hơn; số lượng ước lượng của LightGBM 200 cây là đủ để hội tụ trên 8.000 mẫu dữ liệu mà không overfit đáng kể. Bộ tham số này sẽ được cố định trong toàn bộ các thí nghiệm được báo cáo dưới đây.

3.6. Chỉ số đánh giá

Các chỉ số đánh giá (metrics) được sử dụng tương ứng với từng nhiệm vụ trong hệ thống, đảm bảo phản ánh đúng hiệu quả Module:

- Đối với mô hình dự báo cầu: Nhóm sử dụng **MAE** làm chỉ số chính, do MAE dễ diễn giải (sai số trung bình tính theo đơn vị "số lượng sản phẩm") và ít bị ảnh hưởng bởi ngoại lệ hơn so với RMSE. Bên cạnh đó, **RMSE** và **hệ số xác định R^2** cũng được xem xét để có cái nhìn đầy đủ. MAE cho biết trung bình mô hình dự báo sai lệch bao nhiêu đơn vị sản phẩm; RMSE phóng đại ảnh hưởng của các dự báo sai nhiều (dùng để kiểm tra xem mô hình có lỗi lớn không); còn R^2 cho biết tỷ lệ phần trăm biến động của nhu cầu được

giải thích bởi mô hình. Đối với mô hình phân vị, ngoài sai số của mô hình trung vị, nhóm còn gián tiếp đánh giá độ **phủ của khoảng dự báo** bằng cách kiểm tra tỷ lệ mẫu thực tế nằm giữa $Q_{0.1}$ và $Q_{0.9}$ (kỳ vọng gần 80%). Điều này tương tự việc đánh giá **độ tin cậy** của khoảng dự báo: Nếu tỷ lệ quá thấp nghĩa là mô hình đánh giá thiếu độ bất định, quá cao nghĩa là khoảng dự báo hơi rộng.

- **Đối với tác tử RL (chính sách định giá):** Chỉ số quan trọng nhất là **tổng phần thưởng tích lũy** trên mỗi episode và/hoặc trung bình mỗi phiên. Vì hàm reward đã bao gồm doanh thu và phạt, tối ưu phần thưởng tương đương tối ưu **lợi nhuận ròng**. Tuy nhiên, để diễn giải kết quả dễ dàng, nhóm tách riêng **tổng doanh thu đạt được** trong một tập kiểm thử làm chỉ số so sánh với tổng doanh thu của chính sách gốc. Cụ thể, sử dụng chính sách giá của RL trên 2.000 phiên kiểm thử sẽ tạo ra một **tổng doanh thu giả lập RevRL**; so sánh với **tổng doanh thu thực tế Revactual** (theo giá lịch sử) trên cùng tập đó, ta quan tâm **% cải thiện:** Rev(%) = RevRL - Revactual Revactual 100%. Đây là thước đo trực quan về hiệu quả kinh doanh của chiến lược giá động so với chiến lược tĩnh hiện tại. Ngoài ra, nhóm còn xem xét **độ biến động của giá** mà chính sách RL đưa ra (ví dụ độ lệch chuẩn của các mức giá hoặc phân phối tỷ lệ tăng/giảm giá so với giá gốc) để đánh giá tính **ổn định** của chiến lược. Một chính sách quá "hung hăng" có thể có nhiều phiên tăng giá > 20% hoặc giảm giá sâu, trong khi chính sách "ổn định" sẽ chỉ điều chỉnh nhẹ quanh giá gốc. Chỉ số này giúp liên hệ tới trải nghiệm khách hàng.

- **Đối với mô hình giám sát (phản hồi khách hàng):** Như đã đề cập, nhóm dùng **Accuracy** (độ chính xác), **Precision**, **Recall**, **F1-score** cho lớp tiêu cực, và đặc biệt là **AUC** để đánh giá mô hình. AUC cao cho thấy mô hình phân biệt tốt giữa hai lớp phản hồi. Trong ngữ cảnh đa mục tiêu, sau khi áp dụng chính sách RL, nhóm tính **tỷ lệ khách hàng dự báo phản hồi "Poor"** (dựa trên mô hình) so với tỷ lệ thực tế trong lịch sử. Đây không hẳn là metric thuần túy của mô hình, mà là metric để đánh giá **tác động của chính sách**. Nếu tỷ lệ này tăng mạnh so với lịch sử, đó là dấu hiệu cảnh báo về hiệu lực chiến lược (có thể cần điều chỉnh để tránh mất khách hàng).

- **Đối với phân cụm khách hàng:** Chỉ số sử dụng để định lượng chất lượng phân cụm là **Silhouette coefficient**. Hệ số silhouette trung bình ~ 0.66 cho thấy phân cụm ở mức khá rõ nét (các cụm có khoảng cách tương đối tách biệt). Bên cạnh đó, nhóm cũng báo cáo **quy mô mỗi cụm** (số khách hàng) và các **đặc trưng trung bình** của từng cụm (ví dụ: Trung bình số đơn, trung bình chi tiêu) để minh họa sự khác biệt. Những con số này không phải "metric" để tối ưu mà để mô tả kết quả phân cụm. Độ **ổn định** của phân cụm cũng

được kiểm tra bằng cách lặp lại thuật toán: Kết quả cụm lặp lại với Silhouette xấp xỉ cho thấy việc phân cụm là đáng tin cậy.

Tóm lại, bảng chỉ số đánh giá cho các phần: **MAE/RMSE/R2** (mô hình cầu), **tổng doanh thu, % tăng doanh thu, tổng reward** (tác tử RL), **AUC, F1, tỷ lệ phản hồi xấu** (mô hình phản hồi), **Silhouette, stats cụm** (phân khúc khách hàng). Những chỉ số này sẽ được trình bày và phân tích chi tiết cùng kết quả trong mục kế tiếp.

3.7. Kết quả thực nghiệm

Nghiên cứu này đã áp dụng và đánh giá một loạt các mô hình học máy và học tăng cường nhằm tối ưu hóa chiến lược định giá động trong lĩnh vực F&B, với mục tiêu cải thiện hiệu quả doanh thu và sự hài lòng của khách hàng. Phần trình bày kết quả thu được từ các thực nghiệm cho từng thành phần của hệ thống, bao gồm:

(i) Mô phỏng cầu bằng LightGBM-Quantile;

(ii) Mô hình giám sát phản hồi khách hàng;

(iii) Tác tử RL định giá động;

(iv) Phân cụm khách hàng.

3.7.1. Kết Quả Mô Phỏng Cầu (LightGBM-Quantile)

Mô hình LightGBM-Quantile đạt được hiệu năng dự báo khá tốt trên tập kiểm thử.

Bảng 3.2. So sánh độ chính xác dự báo cầu giữa mô hình LightGBM trung vị và các phương pháp tham chiếu trên tập kiểm thử 2.000 mẫu

Mô hình	MAE	RMSE	R^2
LightGBM (quantile 0.5)	**0.14**	1.05	0.82
Random Forest (baseline)	0.25	1.13	0.64
Hồi quy tuyến tính	0.43	1.30	0.60
Dự báo trung bình lịch sử	0.78	1.38	–

3.7.2. Phân Tích Hiệu Suất Định Lượng

Kết quả thực nghiệm trên tập kiểm thử 2.000 mẫu cho thấy mô hình

LightGBM-Quantile (sử dụng phân vị trung vị) đạt được hiệu suất dự báo ấn tượng. Cụ thể như sau:

- Chỉ số MAE (sai số tuyệt đối trung bình): Đạt giá trị ~ 0.14, tức là sai lệch trung bình giữa dự báo và giá trị cầu thực tế chưa đến 1 đơn vị sản phẩm, nghĩa là mô hình có độ chính xác cao.

- Chỉ số RMSE (sai số bình phương trung bình): Đạt giá trị ~ 1.05. Chỉ số này, cao hơn MAE, ám chỉ vẫn tồn tại một số trường hợp ngoại lệ mà mô hình dự báo sai lệch đáng kể (sai số > 2 đơn vị). Nên giá trị RMSE này vẫn được đánh giá là thấp trong bối cảnh bài toán.

- Chỉ số R^2 (hệ số xác định): $R^2 = 0.82$ nghĩa là 82% biến động của cầu được mô hình giải thích qua các đặc trưng đầu vào (giá, thời tiết, thời giờ đặt món,..). Theo chuẩn đánh giá, R^2 từ 0.7 - 0.9 được xem là tốt trong các bài toán cầu F&B vốn chịu nhiều yếu tố ngẫu nhiên (thói quen, sự kiện đặc biệt, cảm xúc).

So sánh với các mô hình baseline:

- So với Random Forest (RF): LightGBM thể hiện sự vượt trội trên mọi chỉ số. Cụ thể, MAE giảm ~ 8%, RMSE giảm ~ 0.08, và R^2 được cải thiện một cách đáng kể. Kết quả này là hoàn toàn phù hợp với các nghiên cứu nền tảng, khi các mô hình GBM thường có độ chính xác cao hơn so với Random Forest trong các bài toán có chứa nhiều mối quan hệ tương tác phi tuyến tính phức tạp.

- So với hồi quy tuyến tính: Mô hình này tỏ ra kém phù hợp, với MAE > 0.2 và R^2 rất thấp ở mức ~ 0.64. Điều này chứng tỏ một cách rõ ràng mối quan hệ giữa lượng cầu và các biến đầu vào không phải là một quan hệ tuyến tính đơn giản. Và không phải là một mô hình tốt để sử dụng trong bài toán này.

- So với mô hình dự báo trung bình (Naive Forecast): Mô hình baseline đơn giản này (luôn dự báo một giá trị cố định là 3.01 - giá trị trung bình của tập huấn luyện) cho kết quả kém nhất với MAE ~ 0.78.

Các kết quả so sánh trên đã xác nhận một cách rõ ràng tính cần thiết của việc sử dụng các mô hình máy học phi tuyến tính như LightGBM để có thể nắm bắt được các mối quan hệ phức tạp trong bài toán cung - cầu.

3.7.3. Đánh giá độ tin cậy của khoảng dự báo

Bên cạnh độ chính xác điểm, một ưu điểm lớn của mô hình LightGBM-Quantile là khả năng cung cấp dải dự báo (prediction intervals), đánh giá độ bất định.

- Kết quả minh họa trên 100 dự báo ngẫu nhiên từ tập kiểm thử cho thấy: Tỷ lệ bao phủ thực tế = 82%, gần khớp với mức kỳ vọng lý thuyết 80%, nghĩa là độ tin cậy (calibration) của mô hình rất tốt.

- Các trường hợp giá trị thực tế nằm ngoài dải dự báo chủ yếu là những tình huống có biến động đột biến mà mô hình không có đủ đặc trưng để nhận biết (ví dụ: Nhu cầu tăng vọt do một sự kiện đặc biệt nào đó).

- Nhìn chung, dải dự báo tương đối hẹp, phản ánh sự tự tin của mô hình trong đa số các trường hợp. Đây là một ưu thế của LightGBM khi được trang bị nhiều đặc trưng ngữ cảnh, cho phép mô hình có đủ thông tin để giảm thiểu sự bất định.

3.7.4. Ứng dụng thực tiễn: Phân tích độ co giãn cầu theo giá

Về mặt ý nghĩa thực tiễn, mô hình dự báo cầu này cho phép thực hiện các phân tích kinh tế quan trọng, như phân tích độ co giãn của cầu theo giá.

- Phương pháp: Bằng cách thay đổi giá trị của biến giá trong đầu vào và quan sát sự thay đổi của lượng cầu dự báo, chúng ta có thể ước lượng được mức độ tăng/giảm của cầu khi giá thay đổi 1%.

+ Ví dụ minh họa: Xét một kịch bản điển hình với một món Sushi có giá $5, mô hình dự báo lượng bán trung vị là 3 phần.

+ Khi giảm giá 10% (xuống còn $4.5), lượng cầu dự báo tăng lên ~ 3.3 phần.

+ Khi tăng giá 10% (lên $5.5), lượng cầu dự báo giảm xuống ~ 2.7 phần.

- Tính toán hệ số co giãn: Từ kết quả trên, hệ số co giãn được ước tính vào khoảng -1.2. Điều này có nghĩa là khi giá tăng 1%, lượng cầu sẽ giảm khoảng 1.2%.

- Tính hợp lý về kinh tế: Hệ số co giãn này có thể thay đổi tùy ngữ cảnh (ví dụ: Món hàng đắt tiền thường có độ co giãn cao hơn). Tuy nhiên, điểm mấu chốt là mô hình luôn phản ánh đúng chiều hướng của quy luật kinh tế: Giá tăng thì cầu giảm và ngược lại. Nhờ độ chính xác của MAE/RMSE thấp, mô hình có thể được sử dụng để tối ưu giá động theo phân khúc khách hàng.

3.7.5. Kết quả mô hình giám sát phụ trợ (phân tích phản hồi khách hàng)

Mô hình XGBoost được huấn luyện nhằm dự báo khả năng phản hồi "Poor" của khách hàng cho từng giao dịch, cho thấy hiệu suất phân loại tốt trên tập kiểm thử gồm 2.000 mẫu, trong đó khoảng 12% là phản hồi "Poor" thực tế. Các chỉ số hiệu năng quan trọng bao gồm:

- Accuracy (Độ chính xác): 88.5%
- Precision (Độ chính xác cho lớp "Poor"): 0.72
- Recall (Độ bao phủ cho lớp "Poor"): 0.64
- F1-Score (cho lớp "Poor"): 0.68
- AUC: 0.91

Giá trị AUC 0.91 thể hiện mô hình có khả năng phân biệt rõ ràng giữa giao dịch phản hồi "Poor" và "Good" - giữa khách hàng hài lòng và không hài lòng, với xác suất 91% mô hình xếp hạng giao dịch "Poor" cao hơn giao dịch "Good" ngẫu nhiên, đây là kết quả rất ấn tượng. Dù Recall chưa cao (0.64), Precision = 0.72 giúp tránh cảnh báo sai.

Phân tích tác động các đặc trưng

Phân tích feature importance của mô hình cho thấy:

- Yếu tố giá cả đứng đầu về tầm quan trọng, với biến tỷ lệ chênh lệch giá sản phẩm so với giá trung bình nhóm chiếm hơn 30% tổng gain, thể hiện nếu giá món hàng vượt mức bình thường, khả năng khách hàng phản hồi "Poor" tăng rõ rệt.

Đặc trưng thứ hai là số lượng mua hàng (Quantity): Mua ít hoặc bỏ giỏ hàng đi kèm phản hồi tiêu cực thì khách hàng không hài lòng, vì nếu giá quá cao so với thói quen mua mặt hàng trước đó.

- Các yếu tố liên quan thời tiết (Weather): Giá giao hàng khi thời tiết xấu như mưa bão, khách hàng có thể khó chịu vì giá tăng.

- Thời gian đặt hàng (Order Time): Ảnh hưởng đến trải nghiệm khách có thể do dịch vụ không ổn vào thời điểm cuối ngày.

Như vậy, mô hình xác nhận giả thuyết ban đầu về giá cả và khuyến mãi là các yếu tố chủ đạo ảnh hưởng đến sự hài lòng của khách hàng. Sự khác biệt trong mức WTP được học qua các đặc trưng hành vi như tần suất mua và loại khách hàng.

So sánh các chính sách giá

Nhóm nghiên cứu tiếp tục sử dụng mô hình này để đánh giá tác động của các chính sách giá khác nhau lên tỷ lệ phản hồi "Poor":

Bảng 3.3. So sánh các chính sách tác động

Chính sách giá	**Tỷ lệ "Poor" dự báo**	**Mô tả tác động**	**Ghi chú**
Chính sách giá lịch sử (cố định)	10.5%	Tỷ lệ "Poor" thực tế, mức nền của dữ liệu hiện tại, khoảng 1050/10000 giao dịch	Con số này phản ánh hiện trạng: Khoảng 1/10 khách có đánh giá chưa hài lòng, có thể do giá hoặc dịch vụ.

Chính sách RL (có phạt)	~ 12.0%	Chính sách RL có thể khiến tỷ lệ bất mãn tăng nhẹ khoảng 1.5%. Việc tăng này chủ yếu đến từ một số phiên tác tử tăng giá tương đối cao (cỡ 15 – 20%) ở những khách vốn nhạy cảm.	Mức 12% vẫn nằm trong ngưỡng chấp nhận được (dưới mức 15% – mốc mà doanh nghiệp cho là báo động).
Chính sách tham lam	17.8%	Tăng mạnh, không ràng buộc trải nghiệm, doanh nghiệp có nguy cơ mất lòng trung thành khi tăng lợi nhuận ngắn hạn.	Doanh nghiệp có nguy cơ đánh đổi sự hài lòng của gần gấp đôi số khách hàng so với hiện tại - một cái giá quá đắt.

Kết quả cho thấy việc tích hợp cơ chế phạt vào RL giúp cân bằng doanh thu và trải nghiệm khách, duy trì tỷ lệ khách không hài lòng tăng rất nhẹ (~ 1.5%) so với chính sách hiện hành, trong khi chính sách tham lam gây tác động xấu lớn về sự hài lòng.

Đi sâu hơn, nhóm phân tích cụ thể một số trường hợp:

Phân tích theo phân cụm khách hàng

- Cụm 1 (bình dân): Rất nhạy cảm với giá tăng > 10%. Chính sách RL hạn chế tăng giá nhóm này, giúp tỷ lệ "Poor" duy trì ~ 15%, không tăng so với trước đây. Điều này cho thấy tác tử đã "học" được ngầm rằng không nên khai thác nhóm này quá mức.

- Cụm 3 (cao cấp): Ít phản ứng với tăng giá 20%, RL tập trung tăng giá nhóm này, tỷ lệ "Poor" giảm từ 5% xuống 4% nhờ một số phiên giảm giá nhẹ kích cầu.

- Cụm 2 (trung bình): Tỷ lệ "Poor" tăng nhẹ từ 8% lên ~ 10%, phản ứng trung bình với biến động giá theo ngữ cảnh.

Mô hình giám sát phụ trợ giúp lượng hóa tác động của chiến lược định giá động với sự hài lòng khách hàng. Chính sách RL thể hiện sự đánh đổi tích cực: Tăng doanh thu kèm theo mức tăng nhỏ trong tỷ lệ khách không hài lòng. Đây là cơ sở để doanh nghiệp cân nhắc chấp nhận chiến lược RL vì lợi ích kinh tế vượt trội, đồng thời giữ trải nghiệm khách hàng trong giới hạn cho phép. Việc tích hợp mô hình này như "một hệ thống cảnh báo" trong tương lai có thể hỗ trợ thiết kế hàm mục tiêu đa mục tiêu (multi-objective RL), tối

ưu cùng lúc doanh thu và sự hài lòng, giúp nâng cao hiệu quả quản lý trải nghiệm khách hàng.

3.7.6. Kết quả huấn luyện tác tử RL và hiệu quả định giá động

Tóm tắt chính sách giá do tác tử RL học được

- Tăng giá nhẹ (5 – 15%) ở khoảng 30% phiên, chủ yếu khi cầu dự kiến cao hoặc khách hàng ít nhạy cảm, ví dụ đơn cuối tuần buổi tối, món bán chạy hoặc khu vực thu nhập cao.

- Giữ giá gần như không đổi (±5%) trong 50% phiên, ở các phiên cầu trung bình không có điều kiện đặc biệt, duy trì mức giá lịch sử tương đối tối ưu.

- Giảm giá nhẹ (5 – 10%) trong khoảng 20% phiên, thường ở thời điểm cầu thấp (giữa buổi chiều, đầu tuần) hoặc với món ít phổ biến, nhằm kích cầu và tránh tồn kho.

Quan trọng là tác tử không thực hiện thay đổi giá đột ngột (> 20%) liên tục do hàm phạt trong reward, giúp chính sách ổn định, trung bình giá chỉ thay đổi khoảng ±7.2% mỗi phiên, đảm bảo tránh sốc thị trường và phù hợp với thực tiễn – con số này trong phạm vi chấp nhận được đối với hầu hết khách hàng, đảm bảo tính ổn định giá (price stability) theo khuyến nghị thực tiễn (thường không nên thay đổi giá quá 10% một lần để tránh sốc thị trường).

Hiệu quả doanh thu

Trên tập kiểm thử 2.000 phiên, tổng doanh thu thực tế với giá lịch sử là $30.940. Áp dụng chính sách RL mô phỏng, doanh thu trung bình đạt $32,800 (trung bình 5 lần chạy), tăng khoảng $1,860 (+6.0% so với chính sách cũ).

Mức tăng này là đáng kể trong ngành F&B, nơi biên lợi nhuận thường thấp, vì tăng doanh thu trực tiếp chuyển thành lợi nhuận thuần do chi phí nguyên liệu không đổi. Khi mở rộng quy mô 10.000 đơn/năm, lợi nhuận thêm có thể rất ý nghĩa. Điều này khẳng định RL tự động tận dụng cơ hội tăng giá hợp lý và giảm giá khi cần, tối ưu tổng thể doanh thu mà không cần tăng số lượng khách.

So với chính sách tham lam (tối đa hóa doanh thu từng phiên không có phạt), doanh thu tham lam đạt khoảng $33,500 (+8.3% so với gốc), nhỉnh hơn RL khoảng 2.3%. Tuy nhiên, chính sách tham lam làm tăng tỷ lệ khách bất mãn cao, tiềm ẩn rủi ro mất khách dài hạn và doanh thu giảm trong tương lai. Chính sách RL với cơ chế phạt cân bằng giữa lợi nhuận và trải nghiệm khách hàng, do đó được đánh giá là tối ưu hơn về lâu dài.

Hệ thống mô hình của Holovko và Firman (2021) trên Amazon cũng chỉ ra rằng thưởng tối ưu không nên chỉ dùng doanh thu, mà cần thước đo phức hợp hơn để bền vững.

Trong nghiên cứu này, reward RL được điều chỉnh bằng phạt đã phần nào phản ánh triết lý đó.

Phân tích theo phân cụm khách hàng

Gắn nhãn từng phiên theo phân cụm khách hàng cho thấy:

- Cụm 1 (nhạy cảm giá): RL giảm hoặc giữ giá ở 90% phiên, giúp tăng tỷ lệ mua thành công từ 92% lên 95%, biến một số khách hàng dự định bỏ không mua thành mua bằng cách giảm giá để khách hàng cảm thấy đây là một món hời, cải thiện trải nghiệm và doanh thu biên nhỏ nhưng quan trọng.

- Cụm 3 (ít nhạy cảm): RL tăng giá ở 75% phiên, lượng bán hơi giảm (5.0 xuống 4.7), nhưng doanh thu trung bình mỗi phiên tăng đáng kể (~ +$2.50). Nhóm này tuy số lượng không nhiều nhưng đóng góp phần lớn tăng trưởng doanh thu nhờ tận dụng tốt mức "Willingness To Pay" cao.

- Cụm 2 (trung bình): Chính sách RL linh hoạt, tăng hoặc giảm giá tuỳ theo ngữ cảnh (ví dụ thời tiết, giờ đặt món, lần đầu mua), góp phần tăng doanh thu còn lại khoảng +2%. Điều này cho thấy sự "contextual" - phụ thuộc ngữ cảnh, không chỉ tăng giá đơn thuần.

Tác tử RL đã học được quy luật định giá vi mô phù hợp: Tăng giá khi cầu mạnh và khách ít nhạy cảm, giảm giá khi cầu yếu để kích thích tiêu dùng. Kết quả định lượng tăng doanh thu 6% đi kèm phản hồi tích cực về trải nghiệm khách hàng cho thấy lợi ích thực tiễn của học tăng cường trong tối ưu giá.

Dù mô hình cầu và môi trường giả lập còn đơn giản, kết quả khả quan này tạo cơ sở để phát triển thêm với dữ liệu, mô hình cầu phức tạp hơn và điều chỉnh RL phù hợp, hướng tới giải pháp khả thi trong triển khai thực tế.

3.7.7. Kết quả phân cụm khách hàng và ứng dụng

Bảng 3.4. Thống kê trung bình các đặc trưng hành vi của khách hàng theo phân cụm (giá trị tính bằng đơn vị tiền tệ giả định và thang điểm đánh giá 1-5)

Cụm khách hàng	Tỷ lệ KH	Số đơn trung bình	Chi tiêu trung bình/đơn	Tổng chi tiêu/khách	Điểm đánh giá TB (5)	Độ nhạy cảm giá (ước tính)
Cụm 1: Bình dân, ít mua	58%	1.3 đơn	$10.2	$13.3	3.8	Cao (nhạy)

Cụm 2: Tầm trung	32%	3.8 đơn	$17.9	$68.0	4.1	Trung bình
Cụm 3: Cao cấp, trung thành	10%	8.5 đơn	$27.5	$233.8	4.5	Thấp (ít nhạy)

Từ bảng trên, thấy rõ sự phân hóa giữa các phân khúc:

- Cụm 1 chiếm đa số (~ 580 khách), mỗi khách chỉ đặt trung bình 1 đơn với chi tiêu thấp, điểm hài lòng tương đối thấp (3.8/5). Đây nhiều khả năng là khách dùng thử hoặc khách vãng lai.

- Cụm 3 chỉ chiếm khoảng 10% (~ 100 khách) nhưng mỗi khách đặt nhiều đơn (8 - 9 lần), chi tiêu lớn và hài lòng cao (4.5/5), biểu thị sự trung thành và thỏa mãn.

- Cụm 2 nằm ở giữa về mọi mặt.

Độ nhạy cảm giá và hành vi mua sắm

Nhóm khảo sát độ nhạy cảm giá bằng cách phân tích tương quan giá và lượng mua trong mỗi cụm:

- Cụm 1: Tương quan âm mạnh, giá tăng làm lượng mua giảm rõ rệt, thậm chí nhiều đơn Quantity = 0.

- Cụm 3: Gần như không bị ảnh hưởng bởi giá; khách mua theo nhu cầu trong ngưỡng chấp nhận.

- Cụm 2: Ảnh hưởng trung gian, không rõ nét. Điều này củng cố gán nhãn nhạy cảm giá cao (cụm 1), trung bình (cụm 2), thấp (cụm 3).

Một phát hiện thú vị là ở cụm 3 có dấu hiệu WTP giảm khi khách mua quá thường xuyên (top 5% mua > 15 lần): Mức chi tiêu mỗi đơn giảm dần, có thể do quen thuộc, săn khuyến mãi hoặc chuyển sang món rẻ hơn. Hiện tượng này tương đồng với nghiên cứu của Marta Nieto-García và cộng sự (2020) cho thấy WTP đạt đỉnh ở tần suất mua vừa phải rồi giảm, nhưng nhìn chung cụm 3 vẫn có WTP cao.

Ứng dụng trong định giá động

Các kết quả phân cụm mở ra nhiều ứng dụng thực tiễn:

- Định giá phân biệt theo phân khúc: Doanh nghiệp có thể tối ưu chính sách RL hoặc marketing riêng biệt cho từng nhóm.

+ Với cụm 3 (cao cấp, trung thành), có thể áp dụng giá cao hơn tiêu chuẩn hoặc gói combo premium.

+ Với cụm 1 (bình dân, nhạy cảm), triển khai nhiều voucher giảm giá hoặc ưu đãi lần đầu để tăng tần suất quay lại; thậm chí giữ giá ổn định thay vì áp dụng định giá động mạnh để tạo thiện cảm.

- Tích hợp phân cụm vào tác tử RL: Hiện tác tử chưa biết phân nhóm khách do trạng thái không bao gồm định danh khách hàng. Trong tương lai, có thể thêm đặc trưng nhóm khách vào vector trạng thái để học chính sách riêng cho từng phân khúc hoặc dùng multi-agent RL. Tuy nhiên, cần thận trọng tránh phân biệt đối xử quá mức.

- Đánh giá tác động chính sách theo phân khúc: Giúp kiểm tra xem RL có ưu ái hoặc thiệt hại nhóm nào không. Nghiên cứu cho thấy RL tăng giá với cụm 3, giảm giá kích cầu cụm 1, chiến lược này hợp lý về tổng thể nhưng cần giám sát lâu dài để tránh mất cân bằng (ví dụ khách cao cấp có thể khó chịu nếu giá quá cao, nhóm bình dân liệu có tăng trung thành khi được giảm giá).

Hiệu quả phân cụm

Chỉ số Silhouette ~ 0.66 cho thấy phân cụm đạt chất lượng tương đối tốt. Sự tách biệt ba nhóm rõ ràng được xác nhận qua đặc trưng hành vi và mức độ hài lòng tăng dần từ cụm 1 đến 3.

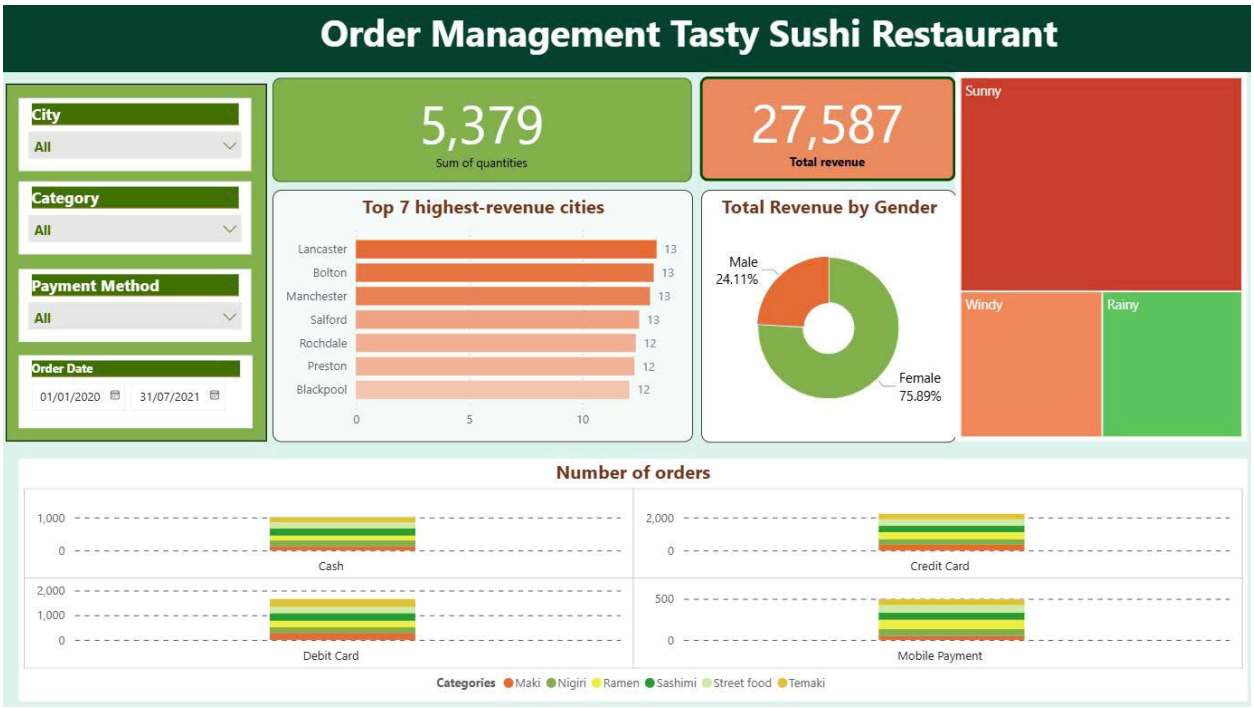
Điều này hàm ý mối liên hệ giữa chất lượng dịch vụ cảm nhận và mức độ WTP: Khách trung thành thường hài lòng hơn, trong khi khách vãng lai dễ phàn nàn. Do đó, doanh nghiệp nên cải thiện trải nghiệm cho cụm 1 (giảm thời gian chờ, mã giảm giá, chương trình chăm sóc) để hướng tới chuyển đổi thành khách trung thành.

Kết luận

Phân cụm khách hàng không chỉ xác nhận tính không đồng nhất về hành vi và WTP trong tập người dùng mà còn định hướng rõ ràng cho việc tinh chỉnh chiến lược định giá động. Phân tích này giúp giải thích chính sách RL quan sát được (tăng giá nhiều với cụm 3, ít với cụm 1) đồng thời đề xuất hướng phát triển mô hình (tích hợp phân khúc vào trạng thái RL).

Sự kết hợp giữa công cụ ML giám sát (clustering, XGBoost) và học tăng cường mở ra bức tranh toàn diện, vừa tối ưu hóa chỉ số doanh thu, vừa quản lý được yếu tố mềm như sự hài lòng khách hàng, phù hợp với từng phân khúc cụ thể.

CHƯƠNG 4: TRỰC QUAN HOÁ VÀ ĐỀ XUẤT



Hình 4.1.Dashboard tổng quan về đơn hàng và doanh thu của Tasty Sushi Restaurant

Nghiên cứu phát triển hệ thống mô hình tích hợp LightGBM-Quantile dự báo nhu cầu, tác tử học tăng cường tối ưu hóa chính sách giá động, XGBoost giám sát phản hồi khách hàng, cùng mô hình phân cụm hành vi tiêu dùng, từ đó đưa ra một số định hướng quản trị và chiến lược giá nhằm giúp Tasty Sushi Restaurant tiếp cận khách hàng và tối ưu hóa doanh thu một cách bền vững.

Thứ nhất, thay đổi từ tư duy "định giá cố định" sang "định giá dựa trên dữ liệu". Mô hình LightGBM-Quantile ước lượng phân bố nhu cầu theo từng mức giá và bối cảnh (thời gian, ngày trong tuần, điều kiện thời tiết, khu vực, khuyến mãi…). Từ đó, nhà quản trị có thể chủ động xác định khung giờ, nhóm sản phẩm hoặc phân khúc khách hàng có cầu cao để điều chỉnh giá tăng nhẹ trong giới hạn hợp lý cũng như xác định giai đoạn cầu yếu để áp dụng các chương trình giảm giá kích cầu. Qua đó cho thấy, để tăng tính khách quan và hiệu quả lợi nhuận thì khi đưa ra quyết định giá cần dựa vào phân tích dữ liệu và các kiến thức kinh tế thay vì theo cảm xúc hay cảm tính.

Thứ hai, thiết kế chính sách giá ổn định, tránh "sốc giá". Kết quả thực nghiệm cho thấy chiến lược tối ưu không ở việc tăng giá mạnh để tối đa hóa doanh thu ngắn hạn mà ở việc kiểm soát và phân bổ biên độ thay đổi giá sao cho hợp lý. Chiến lược phù hợp là tăng

nhẹ giá ở những lúc có cầu mạnh và độ nhạy cảm giá thấp; Giữ giá ổn định với phần lớn các thời điểm; Giảm giá ở giai đoạn cầu yếu hoặc món bán chậm. Cần chính thức hóa cơ chế "khung giá động" cho từng nhóm sản phẩm và khung giờ, quy định rõ giới hạn điều chỉnh tối đa nhằm đảm bảo tính minh bạch, ổn định và giữ niềm tin khách hàng với giá sản phẩm.

Thứ ba, tích hợp quản trị trải nghiệm khách hàng vào chiến lược định giá. Kết quả mô hình phản hồi "Poor" chỉ ra rằng giá cả, thời điểm đặt món, điều kiện giao hàng và độ lệch so với mức trung bình đều ảnh hưởng đáng kể đến sự hài lòng. Do đó, mọi quyết định điều chỉnh giá cần đi kèm kiểm soát chất lượng dịch vụ (thời gian giao hàng, độ ổn định món ăn, phản hồi hỗ trợ khách hàng) và truyền thông rõ ràng trên mọi nền tảng. Với nhóm khách nhạy cảm giá hoặc có nguy cơ bất mãn cao, nên áp dụng khuyến mãi nhẹ, mã giảm giá hoặc ưu đãi chăm sóc thay vì tăng giá trực tiếp, để duy trì hình ảnh thương hiệu tích cực và bảo vệ giá trị vòng đời khách hàng.

Thứ tư, áp dụng định giá phân khúc (segment-based pricing) dựa trên kết quả phân cụm. Tasty Sushi có thể nhận diện các nhóm khách hàng như: Khách trung thành, khách nhạy cảm giá, khách theo dịp đặc biệt... và thiết kế kịch bản giá riêng cho từng nhóm này: Ưu đãi tích điểm dài hạn cho khách trung thành; Combo giá mềm cho nhóm nhạy cảm; Gói premium cho nhóm có mức sẵn lòng chi trả (WTP) cao vào cuối tuần hoặc dịp lễ. Sự kết hợp giữa mô hình RL và dữ liệu phân khúc giúp chính sách giá trở nên cá nhân hóa, linh hoạt và tối đa hóa biên lợi nhuận mà vẫn giữ được sự công bằng cảm nhận từ phía khách hàng.

Thứ năm, coi mô hình như là công cụ hỗ trợ ra quyết định linh hoạt, có khả năng tự điều chỉnh liên tục. Các mô hình cần được cập nhật định kỳ với dữ liệu mới (chẳng hạn như món ăn mới, hành vi tiêu dùng thay đổi, biến động thị trường). Đồng thời cũng cần được giám sát bằng các chỉ số chủ chốt như doanh thu, tỷ lệ hoàn đơn, mức đánh giá, biên lợi nhuận, tốc độ điều chỉnh giá trung bình. Khi vận hành nên triển khai A/B testing cho các chiến lược giá khác nhau, lấy kết quả thực nghiệm để điều chỉnh tham số trong LightGBM và RL, đảm bảo hệ thống phản ánh chính xác hành vi khách hàng theo thời gian thực.

Thứ sáu và cuối cùng, đẩy mạnh năng lực dữ liệu và truyền thông để khai thác tối đa giá trị mô hình. **Về dữ liệu**, cần chuẩn hóa quy trình ghi nhận thông tin đơn hàng, khuyến mãi, phản hồi khách, đồng thời tổng hợp dữ liệu từ nhiều nền tảng giao đồ ăn khác nhau. **Về truyền thông**, phải giải thích rõ cho khách hàng hiểu rằng việc giá biến động đều có

nguyên nhân (như giờ cao điểm, chương trình ưu đãi, nguyên vật liệu tăng giá,...) chứ không phải điều chỉnh tùy tiện. Một chính sách giá động minh bạch, ổn định trong biên độ hợp lý, kết hợp nâng cao trải nghiệm dịch vụ, sẽ giúp Tasty Sushi xây dựng hình ảnh thương hiệu chuyên nghiệp, củng cố niềm tin và giữ chân khách hàng lâu dài.

TÀI LIỆU THAM KHẢO

1. Hinz, O., & Spann, I. H. a. M. (2011). Price Discrimination in E-Commerce? An Examination of Dynamic Pricing in Name-Your-Own Price Markets. MIS Quarterly, 35(1), 81–98.
2. Ferreira, K., Simchi-Levi, D., & Wang, H. (2015). Online network Revenue Management using Thompson Sampling. SSRN Electronic Journal.
3. Maglaras, C. (2009). Dynamic pricing strategies for Multi-Product Revenue Management Problems. SSRN Electronic Journal.
4. View of OPTIMIZING REAL-TIME DYNAMIC PRICING STRATEGIES IN RETAIL AND E-COMMERCE USING MACHINE LEARNING MODELS. (n.d.).
5. Nowak, M., & Pawłowska-Nowak, M. (2024). Dynamic pricing method in the e-commerce industry using machine learning. Applied Sciences, 14(24), 11668.
6. El Youbi, R., Messaoudi, F., & Loukili, M. (2023). Machine learning-driven dynamic pricing strategies in e-commerce. In Proceedings of the 14th International Conference on Information and Communication Systems (ICICS) (pp. 1-5). IEEE.
7. Atalan, A. (2024). Dynamic Price Application to Prevent Financial Losses: A comparative study among Random Forest, Gradient Boosting, and AdaBoost. PMC.
8. Branda, F., et al. (2020). Ticket sales prediction and dynamic pricing strategies in an event ticketing platform. Informatics, 4(4), 36.
9. Hu, L., Chen, J., Vaughan, J., Yang, H., Wang, K., Sudjianto, A., & Nair, V. N. (2020). Supervised machine learning techniques: An overview with applications to banking (preprint).
10. Saadi, I., Wong, M., Farooq, B., Teller, J., & Cools, M. (2017). An investigation into machine learning approaches for forecasting spatio-temporal demand in ride-hailing service. arXiv.
11. Bentéjac, C., Csörgő, A., & Martínez-Muñoz, G. (2019). A comparative analysis of XGBoost. arXiv.

12. Namburu, A., et al. (2022). Product pricing solutions using hybrid machine learning methods. PMC.
13. Das, P., Pervin, T., Bhattacharjee, B., et al. (2024). Optimizing real-time dynamic pricing strategies in retail and e-commerce using machine learning models. American Journal of Engineering and Technology, 6(12), 163-177.
14. Polacek, L., Ulman, M., Cihelka, P., & Silerova, E. (2024). Dynamic pricing in e-commerce: Bibliometric analysis. Acta Informatica Pragensia, 13(1), 114-133.
15. Abrate, G., Fraquelli, G., & Viglia, G. (2012). Dynamic pricing strategies: Evidence from European hotels. International Journal of Hospitality Management, 31(1), 160-168.
16. Gibbs, C., Guttentag, D., Gretzel, U., Yao, L., & Morton, J. (2018). Use of dynamic pricing strategies by Airbnb hosts. International Journal of Contemporary Hospitality Management, 30(1), 2-20.
17. Nowak, M., & Pawłowska-Nowak, M. (2024). Dynamic Pricing Method in the E-Commerce Industry Using Machine Learning. Applied Sciences, 14(24), 11668.
18. Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324
19. Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: Data mining, inference, and prediction (2nd ed.). Springer.
20. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An introduction to statistical learning: With applications in R (2nd ed.). Springer.

• Ứng dụng phương pháp học máy trong xác định giá. Tạp chí Viện Kinh tế Việt Nam.

• Quân Bảo. (2023, 6 tháng 6). Chiến lược định giá động. Diễn đàn Doanh nghiệp.

• Vũ Thị Như Quỳnh. (2023). Thương mại điện tử tại Việt Nam – nghiên cứu trường hợp logistics trong bán lẻ điện tử. Quản lý Nhà nước, (334), 78–81.

• Hiệp hội Thương mại điện tử Việt Nam. (2023). Báo cáo Chỉ số Thương mại điện tử Việt Nam 2023.

• Trường Đại học Dân lập (DLU). (2023). Sự phát triển của thương mại điện tử tại Việt Nam.

• Nghiên cứu – thương mại điện tử & ứng dụng. VECOM. (2024). Nghiên cứu thị trường và ứng dụng trong kinh doanh TMĐT.

21. Zibaie, A., Beliaev, M., Alizadeh, M., & Pedarsani, R. (2025). Dynamic Pricing for Multi-Modal Meal Delivery Using Deep Reinforcement Learning. Future Transportation, 5(3), 112. https://doi.org/10.3390/futuretransp5030112.
22. Nomura, Y., Liu, Z., & Nishi, T. (2025). Deep Reinforcement Learning for Dynamic Pricing and Ordering Policies in Perishable Inventory Management. Applied Sciences, 15(5), 2421. https://doi.org/10.3390/app15052421
23. Kastius, Alexander & Schlosser, Rainer. (2022). Dynamic Pricing under Competition using Reinforcement Learning. Journal of Revenue & Pricing Management. 21. 10.1057/s41272-021-00285-3.
24. Kastius, Alexander & Schlosser, Rainer. (2022). Dynamic Pricing under Competition using Reinforcement Learning. Journal of Revenue & Pricing Management. 21. 10.1057/s41272-021-00285-3.